Diccionario de Datos Final (Parte II)
DS3021 Análisis Computacional de Datos

I. Dataset

Nombre: productos_plazavea_final.csv (dataset analítico final, «Dataset final CSV» oficial de la Parte II).

Volumen: 1437 registros × 21 variables; sin valores nulos y sin duplicados por sku. 479 productos con rebaja observable y 958 sin rebaja.

Dataset limpio completo: productos_plazavea_clean.csv: 1438 registros × 29 variables (todas las filas, columnas limpias, variables derivadas, flags y columnas de trazabilidad).

Origen (raw): productos_plazavea_raw.csv, 1438 registros × 12 variables, 1438 SKU únicos, sin modificar (sha256 3a3833e8312f8d27566083b81cd02a86535055587ba38f25de4e5d05f4348f3a).

Fuente: listado web de la categoría Abarrotes de Plaza Vea Perú (www.plazavea.com.pe/abarrotes), extraído con Selenium y BeautifulSoup (notebook 01_acquisition). Se recorrieron 30 de aproximadamente 65 páginas del listado.

Fecha / snapshot: snapshot único: corrida de extracción de la Parte I (semestre 2026-1). El CSV no incluye un campo de fecha u hora, por lo que la fecha exacta de extracción no se reporta; todas las cifras describen ese único momento.

Generado por: notebook 02_preprocessing.ipynb (limpieza, integración, reducción, transformación y feature engineering). Este diccionario se generó con scripts/build_diccionario_final.py, que calcula tipo, tamaño máximo y valores directamente desde los CSV.

II. Diccionario del dataset final

Convenciones. Tamaño máximo: en variables de texto, longitud máxima en caracteres; en numéricas, número máximo de dígitos (enteros + decimales). Valores: rango mínimo–máximo en numéricas, conteos en binarias y categorías con su frecuencia (n) en categóricas. Debajo de cada nombre se indica su origen: «Original» (columna del raw), «Original (transformada/normalizada/imputada)» o «Derivada» (construida en el preprocesamiento; su fórmula figura en la descripción). Decimales con coma.

Variable	*Descripción*	*Tipo*	*Tamaño máximo*	*Valores*	*Unidad*
sku *Original*	Código del producto en Plaza Vea; clave única del dataset. Se lee como texto (dtype=str) para no perder su carácter de código.	Texto (ID)	8	1437 códigos únicos; longitud 2 a 8 caracteres (ej. 10652532)	-
name *Original (transformada)*	Nombre comercial completo publicado en la tarjeta del producto. Se colapsaron espacios dobles. Base de la imputación de presentation y de is_pack.	Texto libre	116	1437 valores únicos (ej. «Galletas Saladas FIELD Soda Paquete 6un»)	-

Variable	*Descripción*	*Tipo*	*Tamaño máximo*	*Valores*	*Unidad*
brand *Original (normalizada)*	Marca comercial normalizada: strip, espacios colapsados, mayúsculas, unificación de variantes (CASAVERDE➜CASA VERDE, LAYS➜LAY'S, NESTLE➜NESTLÉ) y apóstrofo reconstruido (p. ej. LIBBY S➜LIBBY'S).	Categórico (nominal)	25	271 marcas; más frecuentes: BELL'S (184), COSTA (41), ALACENA (30)	-
category_level1 *Derivada*	Nivel 1 de la jerarquía del catálogo. Fórmula: category.split(' / ')[0].	Categórico (nominal)	9	Abarrotes (1377), Packs (60)	-
category_group *Derivada*	Grupo de categoría (nivel 2). Fórmula: category.split(' / ')[1]. Unidad principal de segmentación del análisis.	Categórico (nominal)	28	12 grupos; más frecuentes: Salsas, Cremas y Condimentos (305), Galletas y Golosinas (254), Snacks y Piqueos (228)	-
subcategory *Derivada*	Subcategoría (nivel 3). Fórmula: category.split(' / ')[2]; si no existe nivel 3 se repite el nivel 2.	Categórico (nominal)	33	70 subcategorías; más frecuentes: Galletas Dulces (106), Chocolates y Lentejas (64), Packs Abarrotes (60)	-
presentation *Original (imputada)*	Envase y contenido publicados (p. ej. «Bolsa 500g»). Los nulos se imputaron con una expresión regular (envase + cantidad + unidad al final de name); ver presentation_imputed.	Categórico (nominal)	23	480 valores; más frecuentes: Bolsa 500g (83), Bolsa 250g (61), Paquete 6un (59)	Envase + cantidad
presentation_imputed *Derivada (flag)*	Indicador de imputación. Fórmula: 1 si presentation era nulo en el raw y se derivó de name; 0 si es el valor publicado.	Binario	1	0 / 1 (1 = 137; 0 = 1300)	-
content_qty *Derivada*	Contenido total del producto en unidad base. Fórmula: cantidad extraída de presentation × factor (kg y L ×1000; oz ×28,3495; se aplica el multiplicador «x N» si existe).	Numérico (decimal)	7 (5 ent. + 2 dec.)	2,00 a 10 000,00	g, ml o un
content_unit *Derivada*	Unidad base de content_qty, extraída de presentation (g = peso, ml = volumen, un = unidades).	Categórico (nominal)	2	g (1121), un (188), ml (128)	-
has_multiplier *Derivada (flag)*	Fórmula: 1 si presentation incluye un multiplicador «x N» (p. ej. «Paquete 6un x 2un») y el contenido se obtuvo multiplicando.	Binario	1	0 / 1 (1 = 18; 0 = 1419)	-
content_validated *Derivada (flag)*	Fórmula: 1 si el contenido de presentation coincide con el que figura en name, o si presentation se imputó desde name. Filtro para comparar unit_price.	Binario	1	0 / 1 (1 = 1326; 0 = 111)	-
current_price *Original*	Precio de venta vigente publicado en el listado en la fecha de extracción.	Numérico (decimal)	4 (2 ent. + 2 dec.)	0,80 a 89,20	Soles (S/)
regular_price *Original*	Precio regular publicado; coincide con current_price cuando no hay rebaja. Se verificó current_price ≤ regular_price en todos los registros.	Numérico (decimal)	5 (3 ent. + 2 dec.)	0,80 a 105,00	Soles (S/)

Variable	Descripción	Tipo	Tamaño máximo	Valores	Unidad
unit_price *Derivada*	Precio normalizado por contenido. Fórmula: current_price / content_qty × 1000 (g, ml) o × 1 (un); 2 decimales. Solo comparable dentro de una misma subcategoría y unidad.	Numérico (decimal)	6 (4 ent. + 2 dec.)	0,04 a 2 590,00 (S/ por kg: 1,90 a 2 590,00; S/ por litro: 2,89 a 279,00; S/ por unidad: 0,04 a 19,95; máximo por kg: ver limitación 6)	S/ por kg, S/ por litro o S/ por unidad
has_discount *Derivada (flag)*	Indicador de rebaja observable. Fórmula: 1 si regular_price − current_price > 0,005; 0 en otro caso.	Binario	1	0 / 1 (1 = 479; 0 = 958)	-
discount_amount *Derivada*	Monto de la rebaja. Fórmula: regular_price − current_price, redondeado a 2 decimales.	Numérico (decimal)	4 (2 ent. + 2 dec.)	0,00 a 15,80	Soles (S/)
discount_pct *Derivada*	Descuento reconstruido (reemplaza al discount original, inválido). Fórmula: (regular_price − current_price) / regular_price × 100, 2 decimales; 0 si has_discount = 0.	Numérico (decimal)	4 (2 ent. + 2 dec.)	0,00 a 38,14 (entre promocionados: 0,69 a 38,14)	%
promotion_intensity *Derivada*	Nivel de profundidad de la rebaja según discount_pct: Sin descuento (0), Bajo (0, 10], Medio (10, 20], Alto (> 20). Cortes justificados por los cuartiles de los promocionados.	Categórico (ordinal)	13	Sin descuento (958), Bajo (109), Medio (249), Alto (121)	-
is_price_outlier *Derivada (flag)*	Fórmula: 1 si current_price > Q3 + 1,5 × IQR (límite calculado sobre los 1438 registros del dataset limpio). Los outliers se conservan: son productos válidos.	Binario	1	0 / 1 (1 = 74; 0 = 1363)	-
is_pack *Derivada (flag)*	Fórmula: 1 si category_level1 = «Packs» o name empieza con «Pack».	Binario	1	0 / 1 (1 = 64; 0 = 1373)	-

Resumen: 21 variables = 6 originales conservadas (3 de ellas transformadas, normalizadas o imputadas) + 15 derivadas. Para leer el CSV conservando sku como texto: pd.read_csv(ruta, dtype={'sku': str}).

III. Variables adicionales del dataset limpio

productos_plazavea_clean.csv contiene las 21 variables anteriores (con las mismas definiciones, calculadas sobre los 1438 registros) más las 8 columnas siguientes, que se conservan solo por trazabilidad y auditoría.

Variable	Descripción	Tipo	Tamaño máximo	Valores	Unidad
brand_original *Original*	Marca tal como fue extraída (antes de normalizar). Trazabilidad de la normalización de brand.	Categórico (nominal)	25	275 marcas (brand normalizada: 272)	-
category *Original*	Ruta jerárquica del catálogo «Nivel 1 / Nivel 2 / Nivel 3»; reemplazada en el dataset final por category_level1, category_group y subcategory.	Categórico (nominal)	72	71 valores; más frecuente: Abarrotes / Galletas y Golosinas / Galletas Dulces (106)	-
seller *Original*	Vendedor que publica el producto. Varianza cero.	Categórico (nominal)	9	plaza vea (1438)	-
stock *Original*	Disponibilidad al momento de la extracción. Varianza cero (el listado solo muestra productos disponibles).	Booleano	4	True (1438)	-

Variable	*Descripción*	*Tipo*	*Tamaño máximo*	*Valores*	*Unidad*
discount_original *Original (renombrada)*	Variable discount del raw, renombrada. Inválida: vale 0 en todos los registros pese a las rebajas observables; se conserva solo como evidencia.	Numérico (decimal)	1	0 en los 1438 registros (mín. = máx. = 0)	%
in_scope *Derivada (flag)*	Alcance del análisis. Fórmula: True si category_level1 ∈ {Abarrotes, Packs}. El dataset final contiene solo in_scope = True.	Booleano	5	True (1437), False (1)	-
product_url *Original*	Enlace a la página del producto (trazabilidad).	Texto (URL)	141	1438 URL únicas; 1438 del dominio plazavea.com.pe	-
image_url *Original*	Enlace a la imagen del producto (trazabilidad). Faltantes por carga diferida (lazy-loading) de imágenes.	Texto (URL)	98	1359 nulos (94,5 %); 79 URL informadas	-

Diferencias de conteo entre el dataset limpio y el final debidas al registro fuera de alcance: marcas 272 vs 271, category_group 13 vs 12, subcategory 71 vs 70, presentation_imputed = 1: 138 vs 137, content_validated = 1: 1327 vs 1326.

IV. Variables y registros excluidos respecto al raw

Variable / registro	*Decisión*	*Motivo*
discount	Excluida (en el limpio como discount_original)	Inválida: vale 0 en el 100 % de los registros aunque 479 productos tienen current_price < regular_price (el selector «-X%» no capturó el texto y fillna(0) ocultó el fallo). Reemplazada por discount_pct.
seller	Excluida (solo en el limpio)	Varianza cero: «plaza vea» en el 100 % de los registros; no segmenta.
stock	Excluida (solo en el limpio)	Varianza cero: True en el 100 %; probablemente el listado solo muestra productos disponibles.
image_url	Excluida (solo en el limpio)	1359 nulos (94,5 %) por carga diferida de imágenes; variable de trazabilidad sin valor analítico.
product_url	Excluida (solo en el limpio)	Trazabilidad; sin valor analítico (sku ya identifica al producto).
category	Reemplazada (solo en el limpio)	Separada en category_level1, category_group y subcategory, más fáciles de agrupar.
Registro sku 9431	Fila excluida (in_scope = False)	Marca SAN SEN, categoría «Frutas y Verduras / Verduras / Verduras Orientales»: fuera del alcance Abarrotes. Es la única fila que no pasa al dataset final (1438 → 1437).

No se eliminó ninguna fila por valores faltantes, duplicados (0 duplicados por sku) ni outliers: los precios altos son válidos y solo se marcan con is_price_outlier.

V. Limitaciones del dataset

1. Snapshot de una sola fecha de extracción: no hay serie temporal y los precios y rebajas cambian continuamente; una nueva corrida producirá cifras distintas.
2. Muestra, no censo: 30 de aproximadamente 65 páginas del listado, en el orden que muestra el sitio (no aleatorio). Solo cubre Abarrotes (incluidos los Packs) de un único retailer.
3. No contiene ventas, demanda, márgenes ni stock real: solo precios y rebajas publicados. Cualquier relación observada es una asociación descriptiva en la muestra extraída.
4. discount_pct se reconstruye a partir de los precios publicados en la tarjeta; depende de la veracidad del precio regular publicado y solo refleja rebajas expresadas como diferencia entre precio regular y actual.
5. presentation tiene 137 valores imputados desde name en el dataset final; el faltante no es aleatorio (se asocia a productos con rebaja y a Packs), por lo que el análisis incluye una prueba de sensibilidad.
6. unit_price mezcla unidades (kg, litro, unidad): solo es comparable dentro de una misma subcategoría y unidad, y conviene filtrar content_validated = 1 (111 registros tienen contenido no confirmado por el nombre). El máximo por kg (S/ 2590,00; chocolate «Bolsa 10g» a S/ 25,90) y casos como «Display 30g» probablemente publican el contenido por unidad, aunque figuren como validados.
7. La normalización de marcas usa un mapeo explícito de variantes; las submarcas (p. ej. VICTORIA GLACITAS) se conservan como marcas distintas, lo que puede fragmentar algunos conteos por marca.