Precios y promociones observables en Abarrotes de Plaza Vea

Proyecto Final · Parte II: preprocesamiento de datos y data analytics product

DS3021 Análisis Computacional de Datos · Prof. Jose Luis Espinoza Melgarejo · UTEC, Lima 2026

- Sebastian Loli Gonzalez
- Piero Max Ortiz Villafuerte
- Diego Mauricio Alarcon Ballivian
- Joaquin Emilio Justo Guillen
- Sofía Fridkas García Chaupis

Los precios y rebajas publicados cambian continuamente: hace falta resumirlos con datos confiables

1 Situación

El listado web publica precio regular y actual de cada producto, pero la oferta y las rebajas cambian continuamente.

2 Necesidad

Un analista de monitoreo necesita saber cuántos productos tienen rebaja, de qué tamaño y en qué categorías y marcas.

3 Pregunta

¿Cómo se distribuyen los precios y los descuentos observables entre marcas y categorías de Abarrotes?

Alcance: snapshot de una fecha de extracción · 30 de ~65 páginas del listado · solo Abarrotes · sin datos de ventas ni demanda

Ajustamos el objetivo a lo que los datos sí permiten medir

Parte I

Qué marcas ofrecen los mayores descuentos y oportunidades de posicionamiento comercial

Objetivo general (Parte II)

Describir la distribución de los precios publicados y la intensidad promocional observable (frecuencia y profundidad de las rebajas reconstruidas a partir de los precios) entre grupos de categoría, subcategorías y marcas de Abarrotes de Plaza Vea Perú, en una muestra de 30 páginas extraída en una fecha, mediante un pipeline reproducible

Seis objetivos específicos

- OE1 Dataset analítico confiable y documentado
- OE2 Precios entre grupos y dentro de subcategorías
- OE3 Frecuencia promocional por grupo y marca
- OE4 Profundidad e intensidad por grupo y subcategoría
- OE5 Relaciones descriptivas y anomalías
- OE6 Reproducibilidad del flujo de datos

Partimos de la cifra oficial: 1438 registros y terminamos con 1437 productos analizables

Raw

1438

registros × 12 columnas

CSV oficial Parte I, sin modificar

›

Limpio

1438

registros × 29 columnas

Todas las filas + features + flags

›

Final analítico

1437

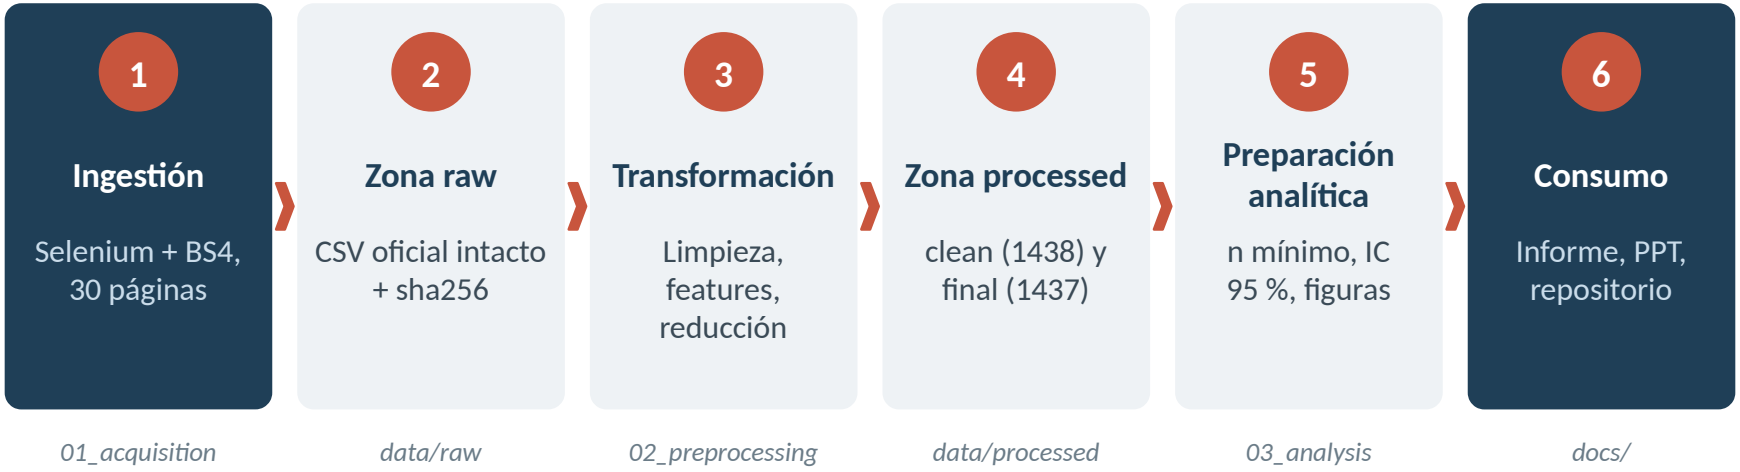
registros × 21 columnas

Solo Abarrotes, columnas analíticas

0 duplicados por SKU: 1438 antes y 1438 después de integrar las 30 páginas.

−1 fila: un producto de Frutas y Verduras queda fuera del alcance (flag in_scope).

Un pipeline de seis fases lleva el dato de la web a métricas trazables



¿Por qué Selenium? El sitio completa las tarjetas con JavaScript: con requests solo llegaban contenedores vacíos.

Fuente única de cifras: reports/metrics.json alimenta informe y presentación.

El descuento almacenado era inválido: lo reconstruimos desde los precios

100 %

de registros con discount = 0

479

productos con precio actual < regular

Diagnóstico	El selector «-X%» no capturó el texto y fillna(0) ocultó el fallo.
Verificación	0 precios actuales > regular y 0 precios ≤ 0: los precios son confiables.
Decisión	Excluir discount y reconstruirlo con la fórmula de abajo.
Resultado	479 promocionados; discount_pct de 0 a 38,14 %.

discount_pct =
(regular_price − current_price) / regular_price × 100

Cada problema de calidad tuvo una decisión documentada, sin perder registros válidos

1 presentation imputada

138 nulos (9,6 %) recuperados desde name con regex + flag

2 image_url excluida

94,5 % de nulos (lazy-loading); solo en dataset limpio

3 Varianza cero

seller y stock con un único valor: no segmentan, se excluyen

4 Marcas normalizadas

275 → 272 marcas; apóstrofo corregido en 24 registros

5 Outliers conservados

74 precios > S/ 27,34 (IQR): válidos, marcados con flag

6 Categoría en 3 niveles

category_level1 / category_group / subcategory

Las variables derivadas convierten precios publicados en medidas comparables

Promoción

has_discount
1 si regular − actual > S/ 0,005

discount_amount
regular − actual (S/)

discount_pct
% de rebaja sobre el regular

promotion_intensity
Sin, Bajo, Medio, Alto (cortes 10 y 20 %)

Producto

category_group / subcategory
niveles 2 y 3 de category

content_qty / content_unit
cantidad y unidad (g, ml, un)

unit_price
S/ por kg, litro o unidad

Calidad (flags)

presentation_imputed
1 si se imputó desde name

is_price_outlier
1 si supera el límite IQR

is_pack
1 si es pack (categoría o nombre)

El dataset final reúne 1437 productos y 21 variables documentadas en el diccionario

1437
productos

271
marcas

12
grupos de categoría

70
subcategorías

479 con rebaja · 958 sin rebaja

Variables reducidas (siguen en el dataset limpio)

- **discount** — inválido: 0 en el 100 %
- **seller, stock** — varianza cero
- **image_url** — 94,5 % de nulos
- **product_url** — solo trazabilidad
- **category** — reemplazada por 3 niveles

Diccionario final: variable, descripción, tipo, tamaño máximo, valores y unidad

Cualquiera puede reproducir el análisis desde el repositorio en tres pasos

`README.md`	instrucciones de uso
`requirements.txt`	dependencias
`data/raw/`	CSV oficial intacto
`data/processed/`	datasets limpio y final
`notebooks/`	01 · 02 · 03 por etapa
`reports/`	figuras, tablas, métricas
`docs/`	diccionarios, informe, PPT

1. **Clonar e instalar**

   pip install -r requirements.txt

2. **Ejecutar 02_preprocessing**

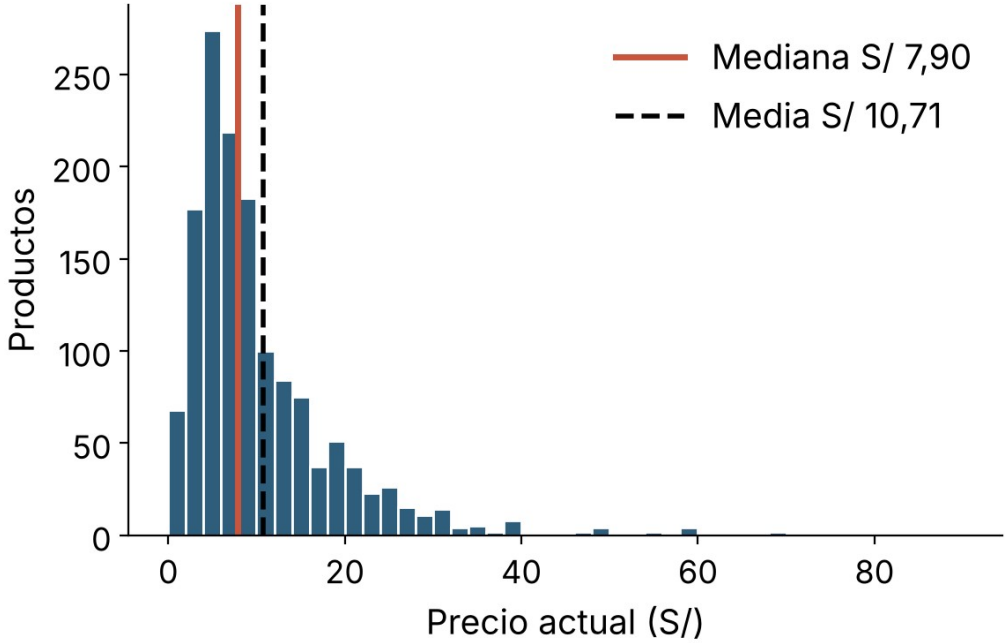
   genera data/processed (limpio y final)

3. **Ejecutar 03_analysis**

   genera figuras, tablas y metrics.json

01_acquisition documenta el scraping; no se re-ejecuta (Colab, Chrome y sitio en vivo).

El 64,2 % de los productos cuesta hasta S/ 10; pocos productos caros estiran la media



Mediana S/ 7,90 < media S/ 10,71

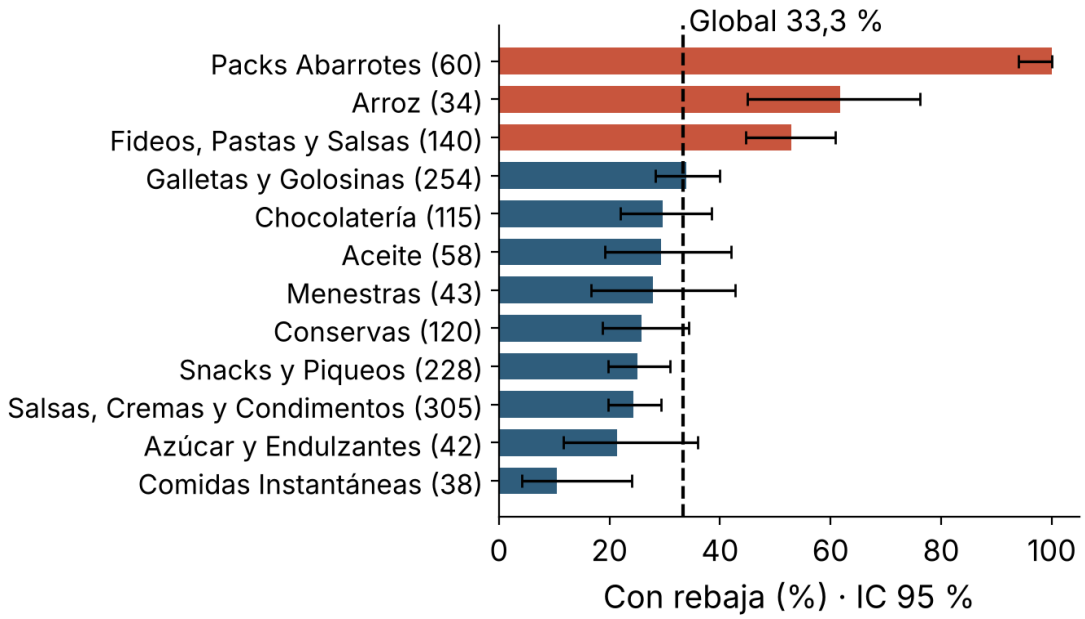
Asimetría 2,79: cola larga a la derecha

Outliers 74 productos sobre S/ 27,34, conservados

Decisión: comparamos segmentos con mediana e IQR

Figura 3 del informe (versión para proyección) · n = 1437

La rebaja no es uniforme: de 10,5 % a 100,0 % según el grupo de categoría



Global: 33,3 % (479/1437)

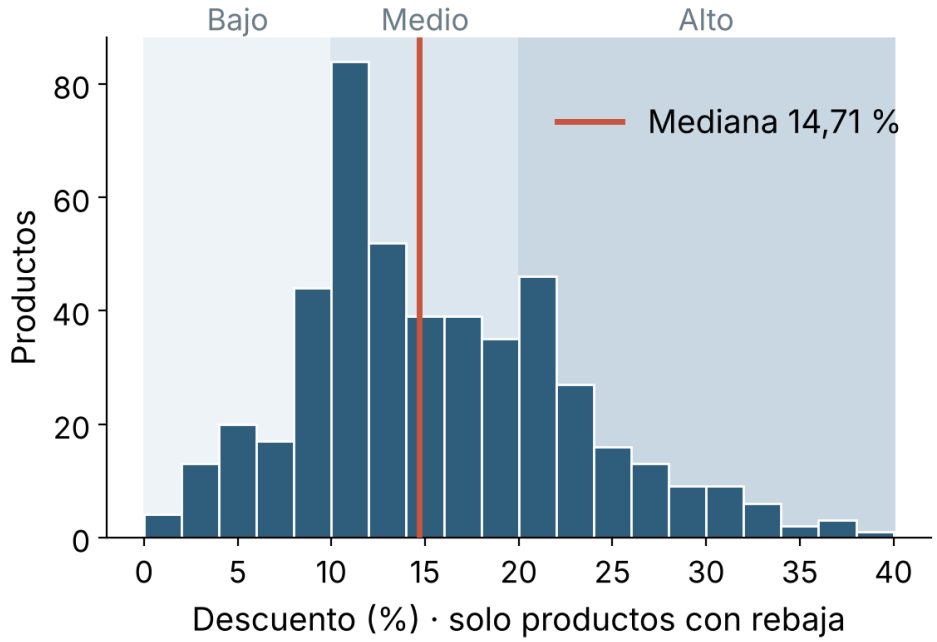
Claramente sobre la global: Packs 100,0 %, Arroz 61,8 %, Fideos 52,9 %

En la global: Galletas y Golosinas 33,9 %

Sin Packs: la tasa global baja a 30,4 %

Figura 6 del informe (versión para proyección) · IC 95 % de Wilson · n = 1437

Cuando hay rebaja, suele ser moderada: la mitad está entre 10 % y 20 %



Mediana 14,71 % (n = 479)

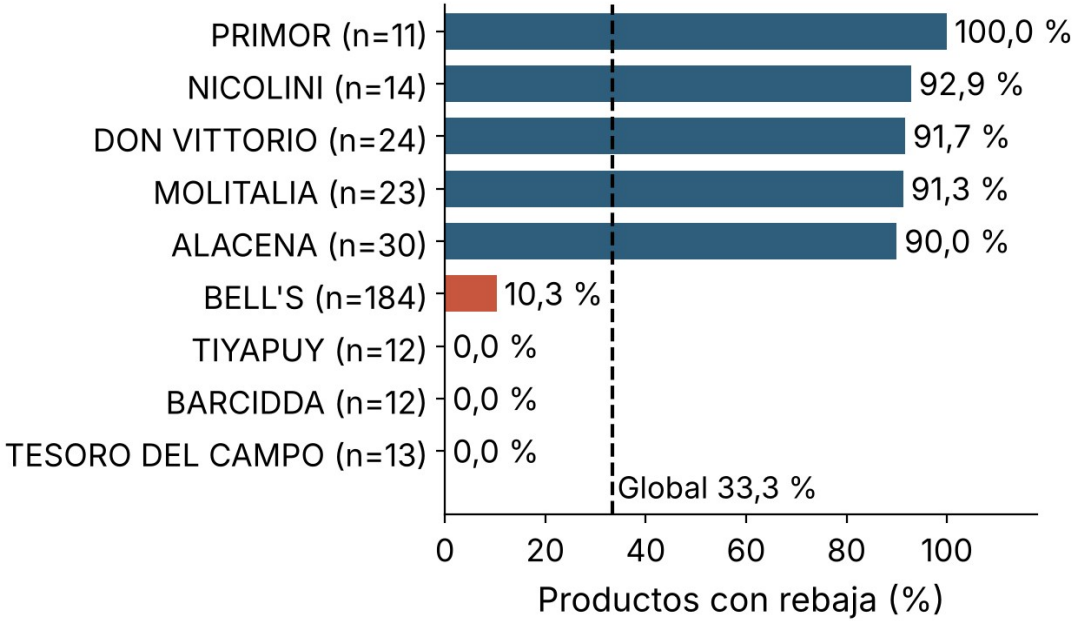
IQR 10,38 % – 20,08 %

Sobre 30 %: solo 21 productos (4,4 %)

Nivel Medio: 52,0 % de los promocionados

Figura 8 del informe (versión para proyección) · solo productos con rebaja · máximo 38,14 %

BELL'S es la marca con más productos, pero solo el 10,3 % tiene rebaja



BELL'S: 184 productos (12,8 % de la muestra)

Tasa de rebaja: 10,3 % vs 36,7 % del resto

Marcas polarizadas: 5 marcas (n ≥ 10) con tasa ≥ 90 % y 3 con 0 %

Figura 7 del informe, simplificada: 9 de las 32 marcas con n ≥ 10 (extremos y BELL'S)

Los casos extremos son válidos y el precio por kg varía mucho dentro de algunas subcategorías

Cinco mayores descuentos (%)

Producto	Desc.
Sal de Maras Fina ONZA Doypack 500g	38,1 %
Passata de Tomate MUTTI Frasco 400g	37,7 %
Tortillas de Maíz TAKIS Buckin' Ranch …	36,8 %
Bombones de Chocolate BON O BON Suprem…	36,4 %
Endulzante SPLENDA Stevia Doypack 175g	35,2 %

+ 12 rebajas simbólicas (< 3 %); ningún extremo es error de captura

Precio por kg o litro (Q3/Q1)

1,20 Arroz Extra

1,90 mediana de las subcategorías

9,35 Sal y Pimienta

Tabla 20 y Figura 5 del informe · 32 subcategorías con n ≥ 15 y contenido validado

Cinco patrones observables en la muestra extraída

100 / 62 / 53 %	La frecuencia se concentra en Packs, Arroz y Fideos; la global (33,3 %) lo oculta
14,7 %	Descuento moderado (10–20 %) y sin asociación con el precio (ρ = 0,02)
10,3 %	BELL'S: tasa vs 36,7 % del resto; precio por kg menor en 9 de 10 subcategorías
5 / 3 marcas	Marcas polarizadas (n ≥ 10): 5 con ≥ 90 % de rebaja y 3 con 0 %, entrelazadas con la categoría
60/60	Packs Abarrotes siempre con rebaja (packs de otras categorías 0/4); eleva la global 2,9 p.p.

Recomendaciones para el analista que monitorea la oferta web

1

Reportar por grupo

Tasa promocional con n e IC 95 %, con y sin Packs Abarrotes

2

Umbrales 10 % / 20 %

Alertar descuentos > 20 % y revisar a mano los > 30 %

3

Rankings con n ≥ 10

Mostrar siempre n; reportar BELL'S por separado

4

% y S/ por separado

El monto en soles crece con el precio; usar % para comparar

5

Mejorar la extracción

Corregir el selector de descuento y repetir en varias fechas

Descriptivo: no evalúa ventas, efectividad de promociones ni competitividad

Un dataset confiable permitió describir la oferta, dentro de límites claros

Conclusiones

- Dataset analítico de 1437 productos, trazable y reproducible, con el descuento reconstruido
- Precios concentrados en valores bajos (mediana S/ 7,90) con cola de productos caros válidos
- Un tercio con rebaja (33,3 %), muy desigual entre grupos y marcas; descuento típico moderado

Limitaciones

- Snapshot de una sola fecha de extracción
- 30 de ~65 páginas, en el orden del listado: muestra no aleatoria
- Solo Abarrotes; sin ventas ni demanda
- Descuento derivado del precio regular publicado
- 137 presentaciones imputadas (análisis de sensibilidad)

Gracias · ¿Preguntas?

Distribución de responsabilidades (asignación del equipo) · todos expusimos

Sebastian Loli

Pipeline y notebook 02: limpieza y outliers

Piero Ortiz

Feature engineering, dataset final y diccionario

Diego Alarcon

Análisis y visualizaciones (notebook 03)

Joaquin Justo

Repositorio GitHub y reproducibilidad

Sofía García

Contexto, insights, conclusiones y edición final