UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA



FACULTAD DE COMPUTACIÓN

CARRERA DE DATA SCIENCE

SEGUNDO AVANCE DEL PROYECTO FINAL:

Análisis de la distribución de precios y la intensidad promocional en la categoría Abarrotes de Plaza Vea Perú

CURSO:

ANÁLISIS COMPUTACIONAL DE DATOS

PROFESOR: Espinoza Melgarejo, Jose Luis

ESTUDIANTES:

- Alarcon Ballivian, Diego Mauricio – 202410104
- García Chaupis, Sofía Fridkas – 202310531
- Justo Guillen, Joaquin Emilio – 202410394
- Loli Gonzalez, Sebastian – 202420022
- Ortiz Villafuerte, Piero Max – 202410409

LIMA – PERÚ

2026

ÍNDICE GENERAL

		Pág.
1	IDENTIFICACIÓN	4
2	CONTEXTO ACTUALIZADO	5
3	OBJETIVOS ACTUALIZADOS	7
4	DATASET Y DICCIONARIO DE DATOS FINAL	9
5	PROPUESTA DE PIPELINE	12
6	PREPROCESAMIENTO DE DATOS	14
7	FEATURE ENGINEERING	19
8	ANÁLISIS Y VISUALIZACIÓN DE DATOS	21
9	INSIGHTS ENCONTRADOS	34
10	CONCLUSIONES	37
11	DOCUMENTACIÓN Y REPRODUCIBILIDAD EN GITHUB	39

ÍNDICE DE FIGURAS

Figura 1. Pipeline de datos del proyecto: ingestión, almacenamiento, transformación y preparación analítica 12
Figura 2. Porcentaje de valores faltantes por variable (dataset raw) 15
Figura 3. Distribución del precio actual 21
Figura 4. Precio actual por grupo de categoría 22
Figura 5. Precio por kg o por litro dentro de subcategorías (n ≥ 15) 23
Figura 6. Tasa promocional por grupo de categoría (IC 95 %) 24
Figura 7. Tasa promocional por marca (n ≥ 10): observada, IC 95 % y esperada por mezcla de grupos 25
Figura 8. Distribución del descuento entre productos con rebaja 26
Figura 9. Intensidad promocional por grupo de categoría 29
Figura 10. Subcategorías con mayor y menor tasa promocional (n ≥ 15) 30
Figura 11. Precio actual vs. descuento (%) entre promocionados 31
Figura 12. Packs Abarrotes frente a packs de otras categorías y al resto de productos 32
Figura A1. Outliers del precio actual según el criterio IQR (n = 1438) 42
Figura A2. Outliers del precio regular según el criterio IQR (n = 1438) 42
Figura A3. Outliers del descuento entre productos con rebaja según el criterio IQR (n = 479) 43
Figura A4. Las 15 marcas con más productos: composición con y sin rebaja 43
Figura A5. Precio regular vs. precio actual (validación de consistencia) 44
Figura A6. Distribución de la intensidad promocional 44
Figura A7. Descuento entre promocionados por grupo de categoría (n promo ≥ 5) 45
Figura A8. Precio regular y actual de productos con y sin rebaja 45

ÍNDICE DE TABLAS

Tabla 1. Distribución de responsabilidades de la Parte II (asignación del equipo) 4
Tabla 2. Preguntas que el dataset permite y no permite responder 6
Tabla 3. Objetivos específicos, análisis asociado y resultado verificable 7
Tabla 4. Ajustes de los objetivos respecto a la Parte I 8
Tabla 5. Volumen y estructura del dataset en cada etapa 9
Tabla 6. Diccionario de datos final (productos_plazavea_final.csv, 1437 registros × 21 variables) 10
Tabla 7. Fases del pipeline: entradas, procesos, salidas, herramientas y justificación 12
Tabla 8. Reglas de dominio evaluadas sobre el dataset raw (n = 1438) 14
Tabla 9. Control de integración y duplicados (antes y después) 14
Tabla 10. Detección de outliers con el criterio IQR (Q1 − 1,5·IQR; Q3 + 1,5·IQR) 16
Tabla 11. Reducción de columnas: decisión sobre cada variable original 17
Tabla 12. Registro de calidad de datos: problema, detección, decisión, resultado y justificación 17
Tabla 13. Variables derivadas: fórmula, significado, motivo y análisis habilitado 19
Tabla 14. Sensibilidad de la distribución de intensidad a la definición de los cortes (n = 479 promocionados) 20
Tabla 15. Sensibilidad de la tasa promocional a los registros imputados y a Packs Abarrotes 26
Tabla 16. Distribución de la intensidad promocional (n = 1437) 27
Tabla 17. Tasa promocional de BELL'S frente al resto de marcas por grupo de categoría (grupos con ≥ 5 productos BELL'S) 27
Tabla 18. Resumen de precio, frecuencia y profundidad promocional por grupo de categoría 28
Tabla 19. Descuento mediano entre promocionados por cuartil de precio actual 31
Tabla 20. Casos extremos: cinco mayores descuentos porcentuales y cinco mayores ahorros en soles 33
Tabla 21. Recomendaciones priorizadas: indicador, umbral o regla y fuente 36
Tabla 22. Conclusiones por objetivo específico: hallazgo, evidencia y significado 37
Tabla 23. Plan de commits del repositorio (por ejecutar desde la cuenta de cada integrante) 40
Tabla 24. Correspondencia entre las figuras del informe y los archivos del repositorio 41

1. IDENTIFICACIÓN

Título del proyecto: *Análisis de la distribución de precios y la intensidad promocional en la categoría Abarrotes de Plaza Vea Perú.*

El proyecto analiza los precios y las promociones **publicados** en el listado web de la categoría Abarrotes de Plaza Vea Perú (plazavea.com.pe). La Parte I construyó, mediante web scraping, el dataset oficial de **1438 productos × 12 variables**. Esta Parte II lo audita, lo limpia y lo transforma en un dataset analítico documentado, construye variables derivadas, analiza patrones de precio e intensidad promocional observable y deja el flujo completo reproducible en un repositorio GitHub.

La Tabla 1 presenta la distribución de responsabilidades acordada por el equipo para la Parte II, con los entregables y la evidencia verificable de cada integrante. Todos los integrantes participan en la preparación y exposición de la presentación final.

Tabla 1. *Distribución de responsabilidades de la Parte II (asignación del equipo)*

Integrante	Código	Responsabilidad en la Parte II	Entregables y evidencia
Sebastian Loli Gonzalez	202420022	Diseño del pipeline y preprocesamiento: integración, reglas de dominio, valores faltantes, outliers y registro de calidad.	`02_preprocessing.ipynb` (secciones 1–6 y 9); secciones 5 y 6 del informe; commits de preprocesamiento.
Piero Max Ortiz Villafuerte	202410409	Feature engineering, reducción de datos y dataset final con su diccionario.	`02_preprocessing.ipynb` (secciones 7, 8 y 10); `productos_plazavea_final.csv`; `diccionario_final`; secciones 4 y 7; commits de features.
Diego Mauricio Alarcon Ballivian	202410104	Análisis exploratorio y visualizaciones (preguntas A–G), métricas e interpretación de figuras.	`03_analysis.ipynb`; `reports/figures`, `reports/tables`, `metrics.json`; sección 8; commits de análisis.
Joaquin Emilio Justo Guillen	202410394	Repositorio GitHub, README, requirements y verificación de la reproducibilidad.	`README.md`, `requirements.txt`, `.gitignore`, estructura de carpetas; sección 11; commits de documentación.
Sofía Fridkas García Chaupis	202310531	Contexto y objetivos actualizados, insights, conclusiones, edición final del informe y coordinación de la presentación.	Secciones 1–3, 9 y 10; `informe_final.pdf`; `presentacion_final.pptx`; commits de documentación.

Fuente: Elaboración propia.

Los cinco frentes de trabajo (preprocesamiento, variables derivadas y dataset, análisis, repositorio y redacción) cubren las 11 secciones del informe y los cuatro entregables exigidos. La misma asignación figura en el README y en el guion de la presentación, y cada aporte se verifica en los notebooks, en las secciones indicadas y en el historial de commits (sección 11.3).

2. CONTEXTO ACTUALIZADO

2.1 Problema y relevancia

Los supermercados en línea publican diariamente miles de precios y rebajas, pero esa información está embebida en páginas web y no en tablas analizables. El **usuario objetivo** del proyecto es el **analista que monitorea los precios y las promociones publicados** en el canal web (por ejemplo, en un equipo de fijación de precios o de gestión de categorías, de inteligencia de mercado o de una marca proveedora). Para ese analista, saber **cómo se distribuyen los precios publicados y con qué frecuencia y profundidad aparecen rebajas** por categoría y marca es un insumo básico de seguimiento descriptivo de la oferta. El problema de la Parte I se mantiene, pero tras adquirir y auditar los datos se redefine con mayor precisión: describir la **intensidad promocional observable** (presencia y profundidad de rebajas reconstruidas a partir de los precios) y la estructura de **precios publicados** en una muestra de la categoría Abarrotes.

2.2 Qué aprendimos tras la adquisición

- **Contenido dinámico.** El listado se construye con JavaScript; `requests` devolvía tarjetas vacías. Se usó Selenium (modo *headless*) para renderizar y BeautifulSoup para leer los atributos `data-*` de cada tarjeta `ga-product-item`. Por ello la adquisición depende de Chrome, red y Colab, y no se re-ejecuta en el pipeline reproducible: la Parte II parte del CSV oficial.
- **Fotografía única (*snapshot*).** Los datos describen el catálogo en **una fecha de extracción**. Precios, surtido y orden del listado cambian continuamente; una nueva corrida produce otra fotografía (las cifras 1407 → 1397 visibles en el notebook de adquisición corresponden a otra corrida y solo se citan como trazabilidad).
- **Muestra, no censo.** Se extrajeron **30 de ~65 páginas** en su orden de aparición (`?page=1…30`). La muestra no es aleatoria: la composición por grupo y marca depende de ese orden, por lo que los resultados no se generalizan al catálogo completo.
- **Calidad distinta a la reportada en la Parte I.** `presentation` tiene **138 nulos (9,6 %)** y no 0,07 %; `image_url` tiene **1359 nulos (94,5 %)** por la carga diferida de imágenes; `seller` y `stock` son constantes en el 100 % de los registros.

2.3 Hallazgo crítico: el descuento no fue capturado

En el CSV oficial, `discount` vale **0 en el 100 % de los registros**, mientras que **479 productos (33,3 %)** tienen `current_price < regular_price`. El rango «0 a 59 %» del informe de la Parte I corresponde a otra corrida. La revisión del notebook de adquisición identificó la causa probable: el texto «-X %» se buscaba con un selector frágil y, en la limpieza, `fillna(0)` convirtió cada fallo de captura en «sin promoción», volviéndolo indistinguible de un producto sin rebaja. Los precios, en cambio, son consistentes (ningún precio ≤ 0 y ningún `current_price > regular_price`).

Decisión: `discount` se declara inválido y se reconstruye a partir de los precios como `discount_pct = (regular_price − current_price) / regular_price × 100`, con rango observado de 0 a 38,14 %. A partir de esa reconstrucción se derivan `has_discount`, `discount_amount` y `promotion_intensity` (sección 7). El hallazgo convierte la validación de reglas de dominio en un paso obligatorio del pipeline.

2.4 Alcance analítico resultante

La Tabla 2 delimita qué preguntas pueden responderse con los datos disponibles y cuáles quedan fuera del alcance.

Tabla 2. *Preguntas que el dataset permite y no permite responder*

Se puede analizar (descriptivo, en la muestra extraída)	No se puede analizar
Distribución y dispersión de precios publicados por grupo, subcategoría y marca.	Ventas, demanda, rotación o preferencias de consumidores.
Frecuencia de productos con rebaja (tasa promocional) con n e IC 95 %.	Efectividad o rentabilidad de las promociones; márgenes o costos.
Profundidad del descuento reconstruido (% y S/) e intensidad Bajo/Medio/Alto.	Evolución temporal de precios (un solo snapshot).
Precio publicado por kg, litro o unidad dentro de una subcategoría.	Competitividad frente a otros retailers (no hay datos de otras tiendas).
Asociaciones descriptivas entre precio, rebaja y formato pack.	Causalidad o motivo de las diferencias entre marcas o categorías.
Casos extremos y anomalías de captura.	Conclusiones sobre las ~35 páginas no extraídas ni sobre otras categorías.

Fuente: Elaboración propia.

Qué muestra: la frontera entre lo que la evidencia permite afirmar y lo que no. **Cuánto:** seis tipos de análisis viables frente a seis preguntas excluidas. **Por qué importa:** evita conclusiones sobre ventas, competitividad o causalidad que los datos no sostienen y fija el lenguaje del informe («intensidad promocional observable», «asociación descriptiva»). **Relación con el objetivo:** es la base del ajuste de objetivos de la sección 3.

3. OBJETIVOS ACTUALIZADOS

3.1 Objetivo general

Describir la distribución de los precios publicados y la **intensidad promocional observable** —frecuencia y profundidad de las rebajas reconstruidas a partir de los precios— entre grupos de categoría, subcategorías y marcas de la categoría Abarrotes de Plaza Vea Perú, a partir de una muestra de 30 páginas extraída en una fecha, mediante un pipeline reproducible de preprocesamiento y análisis, para identificar patrones promocionales y diferencias de precio publicado útiles para el monitoreo de la oferta.

3.2 Objetivos específicos y resultados verificables

La Tabla 3 vincula cada objetivo específico con el análisis que lo responde y con un resultado verificable en el repositorio.

Tabla 3. *Objetivos específicos, análisis asociado y resultado verificable*

Objetivo específico	Análisis / sección	Resultado verificable
OE1. Construir un dataset analítico confiable y documentado, corrigiendo los problemas de calidad detectados.	Preprocesamiento y diccionario (secciones 4 y 6; `02_preprocessing.ipynb`).	1437 × 21 sin nulos ni duplicados; registro de calidad con 16 problemas; diccionario final de 21 variables.
OE2. Caracterizar la distribución de precios actuales y su variación entre grupos y dentro de subcategorías.	8.A (`03_analysis.ipynb`, sección A).	Mediana, IQR y asimetría; precio por grupo; cociente Q3/Q1 del precio por kg o litro en 32 subcategorías con n ≥ 15 y contenido validado.
OE3. Cuantificar la frecuencia promocional global, por grupo de categoría y por marca.	8.B y 8.D.	Tasa global con IC 95 %; tasa por 12 grupos y 32 marcas con n ≥ 10; análisis de sensibilidad.
OE4. Medir la profundidad de los descuentos y comparar la intensidad entre grupos y subcategorías.	8.C y 8.E.	Distribución de `discount_pct`; niveles Bajo/Medio/Alto; resumen por grupo; tasa en 35 subcategorías con n ≥ 15, excluida *Packs Abarrotes*.
OE5. Explorar relaciones descriptivas y anomalías (precio–descuento, packs, casos extremos).	8.F y 8.G.	Correlaciones de Spearman; comparación de packs; listado de casos extremos.
OE6. Garantizar la reproducibilidad del flujo de datos.	Secciones 5 y 11.	Pipeline documentado; repositorio con README, requirements y notebooks ejecutados.

Fuente: Elaboración propia.

Qué muestra: la trazabilidad entre cada objetivo, el análisis que lo responde y la evidencia que lo comprueba. **Cuánto:** seis objetivos específicos: uno de calidad de datos, cuatro analíticos y uno de reproducibilidad. **Por qué importa:** cada objetivo tiene un resultado medible, lo que permite evaluar su cumplimiento en las conclusiones (sección 10). **Relación con el objetivo:** desagrega el objetivo general en metas verificables.

3.3 Ajustes respecto a la Parte I

Los objetivos se reformularon en función de la disponibilidad y calidad real de los datos (Tabla 4).

Tabla 4. *Ajustes de los objetivos respecto a la Parte I*

Planteamiento de la Parte I	Ajuste en la Parte II	Motivo
Analizar «estrategias de precios» de marcas y subcategorías.	Se describen precios publicados e intensidad promocional observable.	Un snapshot sin datos de costos ni ventas no revela estrategias ni motivos.
Usar el porcentaje de descuento extraído (`discount`).	Se reconstruye `discount_pct` desde los precios.	`discount` = 0 en el 100 % pese a 479 rebajas.
Identificar marcas con mayor frecuencia y mayores descuentos.	Ranking solo con n ≥ 10, IC 95 % y tasa esperada por mezcla de grupos.	Marcas con pocos productos producen tasas inestables; marca y categoría están entrelazadas.
Comparar intensidad promocional entre subcategorías.	Intensidad en dos dimensiones (frecuencia y profundidad); subcategorías con n ≥ 15.	Frecuencia y profundidad no siempre coinciden.
Extraer ≥ 1000 productos (OE1 de la Parte I).	Cumplido (1438); se reemplaza por el OE6 de reproducibilidad.	La adquisición quedó cerrada en la Parte I.
Diccionario de 12 variables extraídas.	Diccionario final de 21 variables (originales depuradas y derivadas).	Corrige nulos y rangos erróneos y documenta las nuevas variables.

Fuente: Elaboración propia.

Qué muestra: cómo cambió cada planteamiento de la Parte I al confrontarlo con los datos reales. **Cuánto:** seis ajustes; el más importante es la reconstrucción del descuento, que afecta a los objetivos OE3–OE5. **Por qué importa:** asegura coherencia entre problema, datos y análisis: ningún objetivo exige información que el dataset no contiene. **Relación con el objetivo:** justifica la formulación del objetivo general y de los específicos actualizados.

4. DATASET Y DICCIONARIO DE DATOS FINAL

4.1 Volumen: del dataset raw al dataset final

La Tabla 5 resume el volumen y la estructura del dataset en sus tres etapas: raw, limpio y final.

Tabla 5. *Volumen y estructura del dataset en cada etapa*

Indicador	Raw	Limpio (clean)	Final (analítico)
Archivo (data/)	raw/…_raw.csv	processed/…_clean.csv	processed/…_final.csv
Registros	1438	1438	1437
Variables	12	29	21
Marcas	275	272	271
Grupos de categoría / subcategorías	71 rutas de categoría	13 / 71	12 / 70
Productos con rebaja / sin rebaja	479 / 959 (no registrado en `discount`)	479 / 959	479 / 958
Valores nulos	1497 (presentation 138; image_url 1359)	1359 (solo `image_url`)	0
SKU duplicados	0	0	0

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

El dataset limpio conserva los 1438 registros (29 variables) y el analítico, 1437 (21 variables): solo se excluye un registro fuera de alcance y los nulos pasan de 1497 a 0. El preprocesamiento no elimina filas para «limpiar», sino que corrige, imputa y marca, lo que preserva la tasa promocional y la trazabilidad; así se cumple el OE1 y se fija la base oficial (1437 productos) de las cifras analíticas.

Se mantienen **dos salidas** con fines distintos: el dataset **limpio** conserva todas las columnas (incluidas `discount_original`, `brand_original`, `product_url`, `image_url`, `seller`, `stock` e `in_scope`) para auditoría, y el dataset **final** contiene solo las variables analíticas y los registros dentro del alcance. La diferencia de un registro corresponde al único producto catalogado por el sitio en *Frutas y Verduras / Verduras Orientales* (un fideo chino sin rebaja), que se excluye por el criterio reproducible de alcance de la categoría Abarrotes.

4.2 Variables del dataset final

Las 21 variables se organizan en seis bloques: **identificación** (`sku`, `name`); **segmentación** (`brand`, `category_level1`, `category_group`, `subcategory`); **presentación y contenido** (`presentation`, `content_qty`, `content_unit`); **precio** (`current_price`, `regular_price`, `unit_price`); **promoción** (`has_discount`, `discount_amount`, `discount_pct`, `promotion_intensity`) y **flags de calidad y segmento** (`presentation_imputed`, `has_multiplier`, `content_validated`, `is_price_outlier`, `is_pack`), es decir, indicadores binarios (*flags*). La Tabla 6 documenta cada una con los valores calculados directamente del CSV final. Convención de **tamaño máximo** (la misma del diccionario final): en variables de texto, longitud máxima en caracteres; en numéricas, número máximo de dígitos (enteros + decimales).

Tabla 6. *Diccionario de datos final (productos_plazavea_final.csv, 1437 registros × 21 variables)*

Variable	Descripción	Tipo	Tamaño máx.	Valores	Unidad
`sku`	Código del producto en Plaza Vea; clave única del registro.	Texto (identificador)	8	1437 valores únicos; 2 a 8 dígitos (p. ej., 10652532)	–
`name`	Nombre comercial publicado (marca, descripción y presentación).	Texto libre	116	1437 valores únicos	–
`brand`	Marca normalizada (mayúsculas, variantes unificadas, apóstrofos reconstruidos).	Categórico nominal	25	271 marcas; BELL'S (184), COSTA (41), ALACENA (30), …	–
`category_level1`	Nivel 1 de la jerarquía de categoría del sitio.	Categórico nominal	9	Abarrotes (1377), Packs (60)	–
`category_group`	Nivel 2 de la jerarquía (grupo de categoría).	Categórico nominal	28	12 grupos; Salsas, Cremas y Condimentos (305), Galletas y Golosinas (254), Snacks y Piqueos (228), …	–
`subcategory`	Nivel 3 de la jerarquía; si no existe, repite el nivel 2.	Categórico nominal	33	70 valores; Galletas Dulces (106), Chocolates y Lentejas (64), Packs Abarrotes (60), …	–
`presentation`	Envase y contenido publicados; 137 imputados desde `name`.	Categórico nominal	23	480 valores; Bolsa 500g (83), Bolsa 250g (61), Paquete 6un (59), …	–
`presentation_imputed`	1 si `presentation` era nulo y se derivó de `name`.	Binario	1	0 (1300), 1 (137)	–
`content_qty`	Contenido total en unidad base (aplica el multiplicador «x N»).	Numérico continuo	7	g: 4–10 000; ml: 60–5 000; un: 2–200	g, ml o un
`content_unit`	Unidad base del contenido.	Categórico nominal	2	g (1121), un (188), ml (128)	–
`has_multiplier`	1 si la presentación incluye un multiplicador «x N».	Binario	1	0 (1419), 1 (18)	–
`content_validated`	1 si el contenido coincide con el del nombre o fue imputado desde él.	Binario	1	0 (111), 1 (1326)	–
`current_price`	Precio de venta publicado en la fecha de extracción.	Numérico continuo	4	0,80 a 89,20	S/
`regular_price`	Precio de referencia antes de la rebaja; igual a `current_price` si no hay rebaja.	Numérico continuo	5	0,80 a 105,00	S/
`unit_price`	Precio publicado normalizado por contenido.	Numérico continuo	6	por kg: 1,90–2 590,00; por litro: 2,89–279,00; por unidad: 0,04–19,95	S/ por kg, litro o unidad
`has_discount`	1 si `regular_price − current_price > 0,005`.	Binario	1	0 (958), 1 (479)	–
`discount_amount`	Ahorro absoluto: `regular_price − current_price`.	Numérico continuo	4	0,00 a 15,80	S/
`discount_pct`	Descuento relativo reconstruido (reemplaza a `discount`).	Numérico continuo	4	0,00 a 38,14	%
`promotion_intensity`	Nivel de descuento: Sin descuento (0), Bajo (0; 10], Medio (10; 20], Alto (> 20).	Categórico ordinal	13	Sin descuento (958), Bajo (109), Medio (249), Alto (121)	–
`is_price_outlier`	1 si `current_price` supera el límite IQR (S/ 27,34).	Binario	1	0 (1363), 1 (74)	–
`is_pack`	1 si la categoría es Packs o el nombre empieza con «Pack».	Binario	1	0 (1373), 1 (64)	–

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la definición operativa de cada variable final: significado, tipo, longitud máxima en el CSV, valores observados y unidad. **Cuánto:** 21 variables (6 originales depuradas y 15 derivadas), sin valores nulos; los conteos y rangos se calcularon sobre el CSV final. **Por qué importa:** permite reutilizar el dataset sin

ambigüedad; corrige el diccionario inicial (que declaraba `discount` 0–59 % y casi sin nulos). **Relación con el objetivo:** completa el OE1 y el entregable «diccionario de datos final».

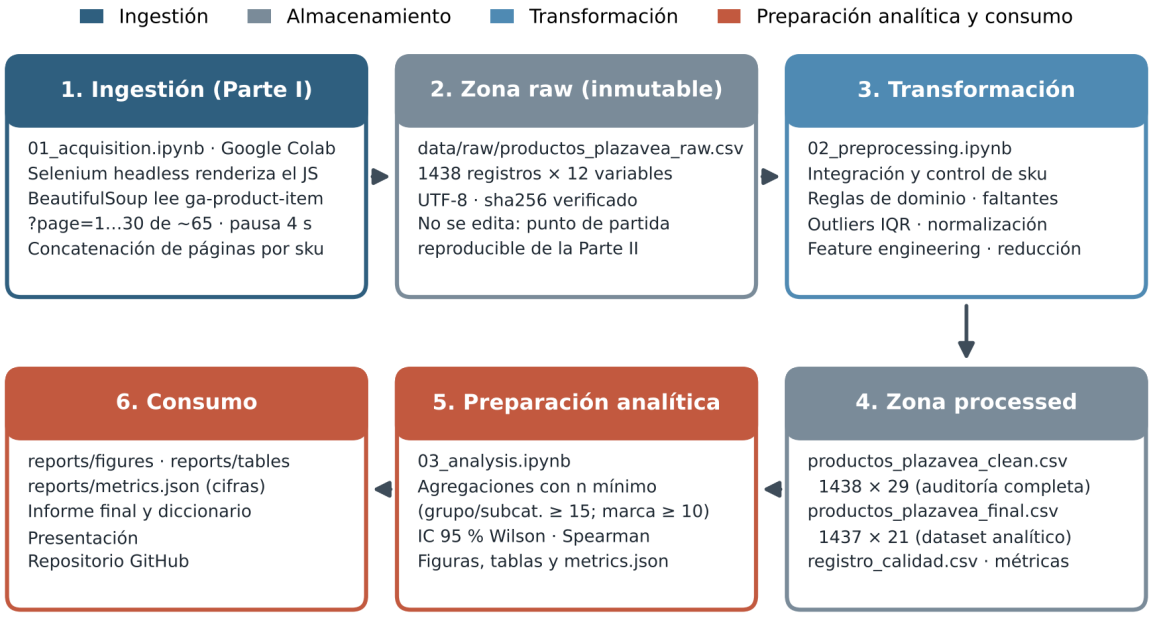
4.3 Limitaciones del dataset

- **Representatividad:** 30 de ~65 páginas en orden de aparición; la mezcla por grupo y marca refleja ese orden (p. ej., BELL'S concentra el 12,8 % de los productos extraídos).
- **Temporalidad:** un solo snapshot; no permite tendencias ni duración de promociones.
- **Descuento reconstruido:** mide la diferencia entre precio regular y actual publicada; no distingue tipos de promoción (p. ej., «2 × 1», precio por tarjeta) que no se reflejen en esos dos precios.
- **Presentación imputada:** 137 registros (9,5 %) provienen del nombre; su tasa de rebaja es mayor (sección 8.B), por lo que se reporta la sensibilidad.
- **Precio unitario:** solo es comparable dentro de una subcategoría y unidad, y solo con `content_validated = 1` (1326 registros). El máximo por kg (S/ 2590,00) corresponde a «Chocolate LA IBÉRICA Milky Bite Size Bolsa 10g» (S/ 25,90): es probable que «10g» sea el peso de cada unidad y no del total, aunque el nombre y la presentación coinciden y por eso figura como validado; algo similar puede ocurrir en *displays* (p. ej., «Display 30g» a S/ 28,80). Por ello el análisis usa medianas y cuartiles, poco sensibles a estos casos.
- **Sin variables de resultado comercial:** no hay ventas, stock real ni costos; `stock` y `seller` eran constantes y se excluyeron.

5. PROPUESTA DE PIPELINE

El pipeline separa cuatro capas: **ingestión**, **almacenamiento**, **transformación** y **preparación analítica**. La Figura 1 muestra el flujo y la Tabla 7 detalla cada fase. El volumen (1438 registros, < 1 MB) no justifica una base de datos: se usan archivos CSV UTF-8 versionados, con una zona *raw* inmutable y una zona *processed* regenerable.

Figura 1. *Pipeline de datos del proyecto: ingestión, almacenamiento, transformación y preparación analítica*



Fuente: Elaboración propia.

Qué muestra: el recorrido de los datos desde el sitio web hasta los entregables, en seis fases conectadas (las mismas de la Tabla 7, del README y de la presentación). **Cuánto:** dos zonas de almacenamiento (raw: 1438 × 12; processed: 1438 × 29 y 1437 × 21) y dos notebooks ejecutables (02 y 03) que transforman y analizan. **Por qué importa:** hace explícito qué se ejecuta en Colab (solo la ingestión) y qué es reproducible localmente, y dónde se aplican los controles de calidad. **Relación con el objetivo:** responde al OE6 y al criterio de pipeline y fundamentos de ingeniería de datos.

Tabla 7. *Fases del pipeline: entradas, procesos, salidas, herramientas y justificación*

Fase (capa)	Input	Proceso	Output	Herramienta	Justificación
1. Ingestión	Listado web de Abarrotes, páginas 1 a 30	Renderizado JS, parseo de tarjetas, pausa de 4 s entre páginas, concatenación y `drop_duplicates(sku)`.	CSV de la corrida oficial	Selenium, BeautifulSoup, pandas (Colab)	El sitio genera el listado con JavaScript; `?page=N` es más estable que el scroll.
2. Zona raw (almacenamiento)	CSV extraído	Copia sin cambios; verificación de hash sha256.	`data/raw/… raw.csv` (1438 × 12)	Git, sha256sum	Fuente única e inmutable: cualquier resultado puede rehacerse desde aquí.

Fase (capa)	Input	Proceso	Output	Herramienta	Justificación
3. Transformación	Zona raw	Perfil, integración y control de duplicados, reglas de dominio, faltantes, outliers IQR, normalización de texto y categorías; reconstrucción del descuento, contenido y precio unitario, intensidad; reducción de columnas y `assert` finales.	DataFrame validado + variables derivadas	pandas, numpy (`02_preprocessing`)	Corrige errores de captura sin eliminar filas válidas y crea las métricas que el análisis necesita.
4. Zona processed (almacenamiento)	Salida de 3	Exportación UTF-8 sin índice; registro de calidad y métricas.	`clean.csv` (1438 × 29), `final.csv` (1437 × 21), `registro_calidad.csv`	pandas, JSON	Separa auditoría (clean) de análisis (final).
5. Preparación analítica	`final.csv`	Agregación con n mínimo, IC 95 % de Wilson, Spearman, pruebas χ^2/Fisher, gráficos.	`reports/figures`, `reports/tables`, `metrics.json`	pandas, matplotlib, seaborn (`03_analysis`)	Todas las cifras del informe se leen de archivos generados, no se transcriben a mano.
6. Consumo	Figuras, tablas, métricas	Redacción del informe, diccionario y presentación; publicación en GitHub.	Informe PDF, diccionario, PPT, repositorio	python-docx, LibreOffice, Git	Entrega trazable a los artefactos del pipeline.

Fuente: Elaboración propia.

Qué muestra: qué entra, qué se hace, qué sale y con qué herramienta en cada fase del pipeline. **Cuánto:** seis fases; solo la primera requiere red y Colab, las cinco restantes se ejecutan localmente con dos notebooks y tres scripts auxiliares. **Por qué importa:** la separación por capas permite repetir la transformación y el análisis sin volver a extraer datos y aislar errores (como el del descuento) en la fase donde se originan. **Relación con el objetivo:** documenta la ruta metodológica que sostiene los OE1–OE6.

Decisiones de ingeniería. (1) *Inmutabilidad*: el raw nunca se sobrescribe y su hash se registra. (2) *Idempotencia*: re-ejecutar `02` y `03` regenera los mismos archivos y cifras. (3) *Validación como código*: el notebook 02 termina con `assert` (0 nulos, 0 duplicados, `current_price ≤ regular_price`, 1437 registros). (4) *Rutas relativas* (`../data`, `../reports`) para ejecutar en cualquier equipo. (5) *Escalabilidad propuesta*: para monitoreo continuo, programar la extracción por fecha (`data/raw/AAAA-MM-DD/`), guardar el texto crudo del descuento y consolidar los snapshots en formato Parquet, sin cambiar las fases 3–6.

6. PREPROCESAMIENTO DE DATOS

El preprocesamiento se implementó en `02_preprocessing.ipynb` y sigue el orden perfil → integración → reglas de dominio → faltantes → outliers → transformación → feature engineering → reducción → registro de calidad → exportación. Cada decisión se tomó con una regla verificable y quedó registrada.

6.1 Validación de reglas de dominio

La Tabla 8 presenta el resultado de las seis reglas de coherencia evaluadas sobre el dataset raw.

Tabla 8. *Reglas de dominio evaluadas sobre el dataset raw (n = 1438)*

Regla	Registros que incumplen	%
`current_price > 0`	0	0,00
`regular_price > 0`	0	0,00
`current_price <= regular_price`	0	0,00
`0 <= discount <= 100 (almacenado)`	0	0,00
discount almacenado = 0 pero current_price < regular_price	479	33,31
discount almacenado coherente con el calculable (|dif| <= 1 p.p.)	478	33,24

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Las reglas de precio se cumplen al 100 %, pero 479 registros (33,31 %) tienen `discount` = 0 con una rebaja visible en sus precios. Los precios son, por tanto, confiables y el descuento almacenado no lo es: esta es la evidencia que justifica reconstruirlo y la que garantiza la validez de `discount_pct`, base de los OE3–OE5.

6.2 Integración interna y duplicados

El proyecto tiene una sola fuente; la integración fue **interna**: la consolidación de 30 páginas extraídas con el mismo parser. Se verificó que la tabla tuviera las 12 columnas esperadas con tipos coherentes y se controlaron duplicados por la clave `sku` (Tabla 9).

Tabla 9. *Control de integración y duplicados (antes y después)*

Control	Antes	Después
Registros	1438	1438
SKU duplicados	0	0
Filas duplicadas (todas las columnas)	0	0
`name` duplicados	0	0
`product_url` duplicadas	0	0
Registros eliminados	–	0

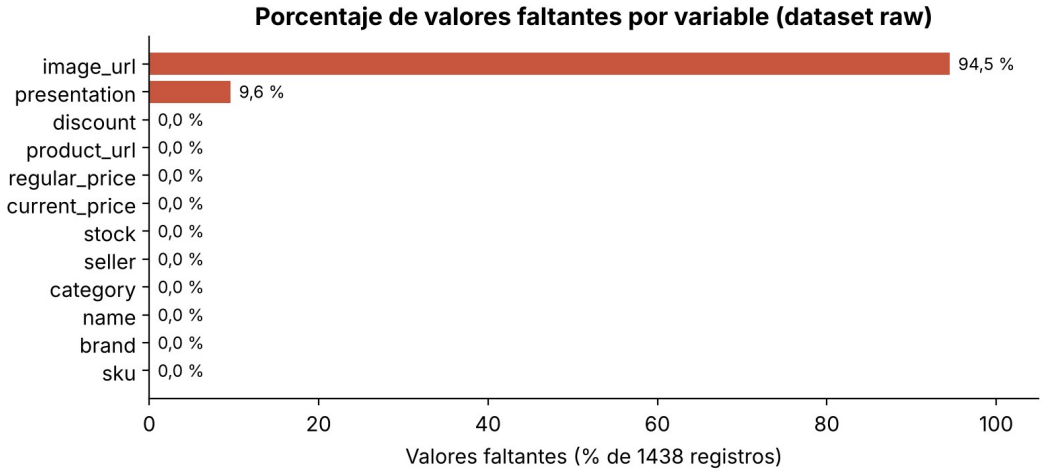
Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

No hay duplicados por SKU, nombre ni URL, y se conservan los 1438 registros. Como un listado que se reordena durante la extracción podría repetir productos entre páginas, el control confirma que cada fila es un producto distinto, que las tasas no están infladas y que la unidad de análisis (un producto = un registro) es válida para todos los objetivos.

6.3 Valores faltantes

La Figura 2 muestra el porcentaje de valores nulos de cada variable del dataset raw.

Figura 2. *Porcentaje de valores faltantes por variable (dataset raw)*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: el porcentaje de valores nulos de cada variable del dataset raw. **Cuánto:** `image_url` tiene 94,5 % de nulos y `presentation` 9,6 %; las otras diez variables, 0 %. **Por qué importa:** los dos faltantes tienen naturaleza distinta: `image_url` responde a la carga diferida de imágenes y no participa del análisis; `presentation` sí es recuperable porque el nombre del producto termina con el envase y la cantidad. **Relación con el objetivo:** define el tratamiento de faltantes del OE1 y corrige la cifra de la Parte I (≈ 0,07 %).

Mecanismo del faltante en `presentation`. El faltante **no es aleatorio**: entre los 138 registros sin presentación el 55,1 % tiene rebaja, frente al 31,0 % de los 1300 restantes; 37 de los 138 son *Packs* (el 61,7 % de esa categoría) y, aun sin *Packs*, la diferencia persiste (38,6 % frente a 29,8 %). Eliminar esas filas habría subestimado la tasa promocional. (Estas cifras se calculan sobre el dataset raw, n = 1438; en la sección 8 la base es el dataset final, n = 1437, y la tasa de los imputados es 55,47 %, Tabla 15.)

Tratamiento. Se imputó con una expresión regular construida con los 25 tipos de envase observados y las unidades de medida (g, kg, ml, L, un), admitiendo multiplicadores («x 2»). Se recuperaron **138 de 138** valores (0 «No especificado») y se creó el indicador `presentation_imputed`. **Validación:** en los 1300 registros con presentación publicada, el patrón aparece en el 98,2 % de los nombres y, entre esos 1277, el envase coincide en el 91,0 % (115 discrepancias). `image_url` no se imputa: se conserva solo en el dataset limpio.

6.4 Inconsistencias de texto y marcas

La detección de variantes fue sistemática: una clave en minúsculas, solo alfanumérica y sin acentos agrupó las escrituras de una misma marca. Se unificaron 3 variantes (`CASAVERDE` → `CASA VERDE`, `LAYS` → `LAY'S`, `NESTLE` → `NESTLÉ`), lo que reduce las marcas de **275 a 272**; se reconstruyó el apóstrofo perdido en 24 registros de 4 marcas (p. ej., `LIBBY S` → `LIBBY'S`) usando el nombre del producto como referencia verificable; se colapsaron dobles espacios en 5 nombres y 8 presentaciones. Las 9 parejas marca/submarca (p. ej., `VICTORIA` / `VICTORIA GLACITAS`) se conservaron como marcas distintas porque así las publica el sitio y no existe una regla objetiva de agregación. La marca original se guarda en `brand_original`.

6.5 Outliers

La Tabla 10 resume los límites IQR y los valores atípicos (*outliers*) de las tres variables numéricas centrales.

Tabla 10. *Detección de outliers con el criterio IQR (Q1 − 1,5·IQR; Q3 + 1,5·IQR)*

Variable	Base (n)	Q1	Q3	IQR	Límite superior	Outliers	Máximo	Decisión
`current_price` (S/)	1438	4,90	13,88	8,98	27,34	74 (5,15 %)	89,20	Conservar y marcar (`is_price_outlier`)
`regular_price` (S/)	1438	5,12	14,50	9,38	28,57	74 (5,15 %)	105,00	Conservar sin flag (redundante)
`discount_pct` (%), solo con rebaja	479	10,38	20,08	9,70	34,63	6 (1,25 %)	38,14	Conservar; revisión en 8.G

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: los límites IQR y el número de valores atípicos de las tres variables numéricas centrales. **Cuánto:** 74 precios actuales (5,15 %) superan S/ 27,34, concentrados en *Aceite* (27) y *Chocolatería* (14); solo 6 de 479 descuentos superan 34,63 %. **Por qué importa:** los valores extremos son válidos (aceites de oliva, endulzantes, *displays* y presentaciones grandes); eliminarlos sesgaría el análisis hacia productos baratos. El IQR del descuento se calcula solo entre promocionados porque el 66,7 % de ceros es estructural. **Relación con el objetivo:** preserva la distribución real para el OE2 y justifica el uso de medianas en todo el análisis.

Los cuartiles de la Tabla 10 se calculan sobre el dataset limpio (n = 1438); en la sección 8 la base es el dataset final (n = 1437), por lo que el Q3 del precio actual pasa de S/ 13,88 a S/ 13,90. Las gráficas de caja de cada variable son las Figuras A1–A3 del Anexo A.

6.6 Transformación

- **Jerarquía de categoría:** `category` («Nivel 1 / Nivel 2 / Nivel 3», 71 valores) se separó en `category_level1`, `category_group` y `subcategory`; en los 62 registros con ruta de dos niveles (2 rutas: *Packs / Packs Abarrotes* y *Abarrotes / Salsas, Cremas y Condimentos*) el nivel 3 repite el nivel 2.
- **Tipos:** `sku` se lee como texto (identificador de 2 a 8 caracteres); `stock` se tipifica como booleano; los precios, como numéricos.
- **Descuento:** `discount` se renombra `discount_original` (evidencia del fallo, solo en el dataset limpio) y se reemplaza por `discount_pct`.
- **Contenido:** la cantidad publicada se lleva a una unidad base (kg y L × 1000; oz × 28,3495; se aplica «x N») para calcular `unit_price`.

6.7 Reducción de datos

La Tabla 11 registra la decisión tomada sobre cada una de las 12 variables extraídas.

Tabla 11. *Reducción de columnas: decisión sobre cada variable original*

Variable raw	Decisión	Justificación
`sku`	Se conserva	Identificador único del producto (clave)
`brand`	Se conserva (normalizada)	Segmentación por marca
`name`	Se conserva	Descripción; base de la imputación y de is_pack
`category`	Se reemplaza	Separada en category_level1 / category_group / subcategory
`seller`	Se excluye	Varianza cero: 'plaza vea' en el 100 %
`stock`	Se excluye	Varianza cero: True en el 100 %
`presentation`	Se conserva (imputada)	Envase y tamaño; flag presentation_imputed; base de content_qty y unit_price
`current_price`	Se conserva	Variable analítica central (S/)
`regular_price`	Se conserva	Variable analítica central (S/)
`discount`	Se excluye	Inválida: 0 en el 100 % pese a 479 rebajas; reemplazada por discount_pct
`product_url`	Solo dataset limpio	Trazabilidad; sin valor analítico (sku ya identifica)
`image_url`	Solo dataset limpio	94,5 % nulos por lazy-loading; sin valor analítico

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Seis variables se conservan (dos de ellas transformadas), `category` se sustituye por tres niveles, tres se excluyen por no aportar información (`seller`, `stock`, `discount`) y dos quedan solo en el dataset limpio. La reducción disminuye la dimensionalidad sin perder trazabilidad, porque las variables sin varianza o inválidas no pueden segmentar ni medir promociones, y concentra el dataset final en las variables que responden a los OE2–OE5.

La reducción es por columnas; de filas, solo se excluye el registro fuera de alcance (flag `in_scope`).

6.8 Registro de calidad de datos

La Tabla 12 consolida todos los problemas detectados, generada por el notebook y exportada a `reports/tables/registro_calidad.csv`.

Tabla 12. *Registro de calidad de datos: problema, detección, decisión, resultado y justificación*

Problema	Detección	Decisión y técnica	Resultado	Justificación
Descuento almacenado inválido	Regla de coherencia: discount = 0 en 100 % y 479 productos con current_price < regular_price	Descartar discount y reconstruirlo. discount_pct = (regular − current)/regular × 100; has_discount con tolerancia S/ 0,005	479 promocionados; discount_pct de 0 a 38,14 %	El selector '-X%' no capturó el texto y fillna(0) lo ocultó; los precios sí son confiables
Nulos en presentation	isna(): 138 nulos (9,60 %); tasa de rebaja 55,1 % en nulos vs 31,0 % en no nulos	Imputar desde name, no eliminar filas. Regex envase + cantidad/unidad al final del nombre + flag presentation_imputed	138 recuperados; 0 'No especificado'	Faltante no aleatorio (asociado a rebaja y a Packs; sin Packs 38,6 % vs 29,8 %): eliminar sesgaría la tasa promocional; la información está en el nombre
Envase de presentation distinto al del nombre	Comparación de la primera palabra de presentation con el envase extraído de name (no nulos)	Respetar el valor publicado. Sin transformación; se documenta	115 registros con envase distinto (p. ej. 'Bolsa 6un' vs 'Paquete 6un')	Inconsistencia del retailer entre tarjeta y nombre; no hay criterio para preferir uno

Problema	Detección	Decisión y técnica	Resultado	Justificación
Nulos masivos en image_url	isna(): 1359 nulos (94,51 %)	No imputar; excluir del dataset analítico. Reducción de columnas	Conservada solo en dataset limpio	Lazy-loading de imágenes (hipótesis); variable de trazabilidad sin valor analítico
Variantes de marca	Clave alfanumérica en minúsculas y sin acentos (groupby)	Unificar a la escritura más frecuente. strip + upper + mapeo de variantes; brand_original como respaldo	Marcas: 275 → 272 (CASAVERDE, LAYS, NESTLE; 3 registros)	Evitar fragmentar los conteos y tasas por marca
Apóstrofo perdido en marcas	Marcas que terminan en ' S' (regex) y búsqueda de "X'S" / "XS" en name	Reconstruir la escritura desde name. Mapeo CRICKET S → CRICKETS, HELLMANN S → HELLMANN'S, LIBBY S → LIBBY'S, SNYDER S → SNYDER'S	24 registros corregidos; el número de marcas no cambia	Error de captura (apóstrofo convertido en espacio); el nombre del producto es la referencia verificable
Submarcas	Marcas que empiezan con otra marca + espacio (p. ej. VICTORIA / VICTORIA GLACITAS)	Conservar como marcas distintas. Sin transformación; se documenta	9 pares detectados; VICTORIA queda con n = 13 en el ranking	Así las publica el retailer; no hay regla objetiva de agregación y el prefijo da falsos positivos
Dobles espacios internos en textos	str.contains(r'\s{2,}'): 5 en name y 8 en presentation	Colapsar a un espacio. str.strip() + str.replace(r'\s+', ' ')	0 dobles espacios tras la limpieza	Evita falsas diferencias al agrupar o comparar textos
Variables de varianza cero (seller, stock)	nunique() = 1 en ambas	Excluir del dataset analítico. Reducción de columnas	Conservadas solo en dataset limpio	No segmentan; el listado muestra solo productos disponibles de la tienda
Categoría jerárquica en un solo texto	split(' / '): 71 valores, 2 o 3 niveles	Separar niveles. category_level1, category_group, subcategory (nivel 3 o repetición del nivel 2)	13 grupos, 71 subcategorías (dataset limpio); 12 y 70 en el analítico	Permite agregar a distintos niveles de detalle
Registro fuera de alcance	Nivel 1 = 'Frutas y Verduras' (1 registro)	Excluir del dataset analítico. Flag in_scope	Dataset final: 1437 registros	El proyecto se delimita a Abarrotes
Outliers de precio actual	IQR sobre current_price: límite superior S/ 27,34 (calculado sin redondear)	Conservar y marcar. Flag is_price_outlier (solo sobre current_price)	74 productos marcados	Precios altos válidos (aceite de oliva, endulzantes, packs, displays); regular_price tiene los mismos 74 outliers y un segundo flag sería redundante
Outliers de descuento	IQR sobre discount_pct entre promocionados: límite superior 34,63 %	Conservar sin flag. Listado de revisión (sección 8.G)	6 de 479 promocionados (1,25 %); máximo 38,14 %	Coherentes con sus precios; no son errores de captura
Contenido no estructurado en presentation	Regex cantidad + unidad (+ multiplicador) sobre presentation	Crear content_qty, content_unit, has_multiplier y unit_price. Conversión a g/ml/un y precio por kg, litro o unidad	1438 de 1438 con contenido; coincide con el nombre en 93,1 % de los no imputados	Permite comparar precios dentro de una subcategoría sin el efecto del tamaño
Duplicados por SKU	duplicated(subset='sku')	Eliminar si existieran. drop_duplicates(subset='sku')	1438 / 0 / 0 / 1438	Clave de la integración de 30 páginas
Tipo de sku	Longitudes 2–8 caracteres	Mantener como texto. dtype str al leer el CSV	sku sin pérdida de formato	Es identificador, no magnitud

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la trazabilidad completa de las decisiones de calidad, de la detección al resultado. **Cuánto:** 16 problemas tratados: 1 descuento inválido, 2 variables con faltantes, 5 de texto, envase y marcas, 2 de estructura, 1 de alcance, 2 de outliers, 1 de contenido y 2 de controles de clave y tipo (duplicados por SKU y tipo de `sku`). **Por qué importa:** cada decisión es reproducible desde el código y justificada con evidencia, lo que permite auditar el dataset final. **Relación con el objetivo:** cierra el OE1 con un dataset final verificable.

7. FEATURE ENGINEERING

Las variables derivadas se crearon solo cuando habilitan un análisis concreto de la sección 8 (Tabla 13).

Tabla 13. *Variables derivadas: fórmula, significado, motivo y análisis habilitado*

Variable	Fórmula / regla	Significado	Motivo	Análisis habilitado
`has_discount`	1 si `regular_price − current_price > 0,005`	El producto muestra rebaja	`discount` es inválido; la tolerancia evita errores de redondeo	Tasa promocional (8.B, 8.D, 8.E)
`discount_pct`	(`regular − current`) / `regular` × 100, 2 decimales	Descuento relativo observado	Reemplaza a `discount`	Profundidad, relación con el precio (8.C, 8.F)
`discount_amount`	`regular_price − current_price`	Ahorro en S/	Un 10 % no equivale en soles entre productos de distinto precio	Ahorro absoluto, anomalías (8.C, 8.G)
`promotion_intensity`	Sin descuento / Bajo (0; 10] / Medio (10; 20] / Alto (> 20)	Nivel de profundidad	Categorías legibles; cortes ≈ Q1 y Q3 (7.1)	Intensidad por grupo (8.C, 8.E)
`category_level1`, `category_group`, `subcategory`	Separación de `category` por « / »	Jerarquía del catálogo	`category` mezcla tres niveles	Segmentación (8.A, 8.B, 8.E)
`content_qty`, `content_unit`	Cantidad × multiplicador en g, ml o un	Contenido total publicado	Los precios absolutos mezclan tamaños	Base de `unit_price`
`unit_price`	`current_price / content_qty` × 1000 (kg o L) o × 1 (un)	Precio normalizado por contenido	Comparar dentro de una subcategoría sin el efecto del tamaño	Precio por kg o litro (8.A, 8.D)
`content_validated`, `has_multiplier`	Coincidencia con el nombre; presencia de «x N»	Calidad del contenido	88 presentaciones contradicen el nombre	Filtro de `unit_price` (8.A)
`presentation_imputed`	1 si `presentation` se derivó de `name`	Origen del dato	Faltante no aleatorio	Sensibilidad de la tasa (8.B)
`is_price_outlier`	1 si `current_price` > S/ 27,34 (IQR)	Precio atípico	Se conservan, pero se identifican	Anomalías (8.G)
`is_pack`	1 si nivel 1 = Packs o `name` empieza con «Pack»	Formato pack	Separar formato y categoría (60 de 64 coinciden)	Packs vs. resto (8.F)

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: las 15 variables derivadas con su definición operativa y el análisis en que se usan. **Cuánto:** 4 variables de promoción, 3 de segmentación, 6 de contenido y calidad (`content_qty`, `content_unit`, `unit_price`, `content_validated`, `has_multiplier`, `presentation_imputed`) y 2 indicadores de segmento o atipicidad (`is_price_outlier`, `is_pack`); ninguna se creó sin un uso analítico. **Por qué importa:** sin `discount_pct` y `has_discount` no sería posible medir promociones; sin `unit_price` las comparaciones de precio entre marcas estarían dominadas por el tamaño del envase. **Relación con el objetivo:** habilita directamente los OE2–OE5.

7.1 Justificación de los cortes de promotion_intensity

Entre los 479 productos con rebaja, Q1 = 10,38 %, mediana = 14,71 % y Q3 = 20,08 %. Los cortes redondos 10 % y 20 % coinciden prácticamente con Q1 y Q3: *Bajo* ≈ cuarto inferior, *Medio* ≈ mitad central y *Alto* ≈ cuarto superior, y son legibles comercialmente. Como hay 11 descuentos de exactamente 10,00 % y 11 de exactamente 20,00 %, se evaluó la sensibilidad a la regla de los bordes (Tabla 14).

Tabla 14. *Sensibilidad de la distribución de intensidad a la definición de los cortes (n = 479 promocionados)*

Definición de cortes	Bajo (%)	Medio (%)	Alto (%)	Nivel predominante	Packs en Alto (%)
10/20, intervalos (a, b] (elegido)	22,8	52,0	25,3	Medio	43,3
10/20, intervalos [a, b)	20,5	52,0	27,6	Medio	50,0
Cuartiles exactos 10,38 / 20,08, (a, b]	25,1	50,1	24,8	Medio	43,3

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: cómo cambia el reparto de los promocionados entre niveles con tres reglas de corte distintas. **Cuánto:** *Medio* reúne entre 50,1 % y 52,0 % en las tres alternativas; la proporción de *Packs Abarrotes* en *Alto* varía entre 43,3 % y 50,0 %. **Por qué importa:** las conclusiones no dependen de la regla elegida; se mantienen los cortes redondos por legibilidad y porque una rebaja redonda de 20 % se agrupa con el estándar central. **Relación con el objetivo:** valida la variable que operacionaliza la «intensidad» del OE4.

7.2 Variables de contenido y de formato

`unit_price` se valida contra el nombre: en los 1277 registros no imputados cuyo nombre indica el contenido, ambos coinciden en el 93,1 %. Las discrepancias (p. ej., «Lata 140un» en un atún de 140 g) no se corrigen por falta de una regla segura; se marcan con `content_validated` y el análisis usa solo los 1326 registros validados del dataset final. `is_pack` es casi redundante con `category_group = Packs Abarrotes`, pero se conserva porque los 4 packs ubicados en otras categorías permiten contrastar el **formato** pack con la **categoría** Packs del listado (8.F).

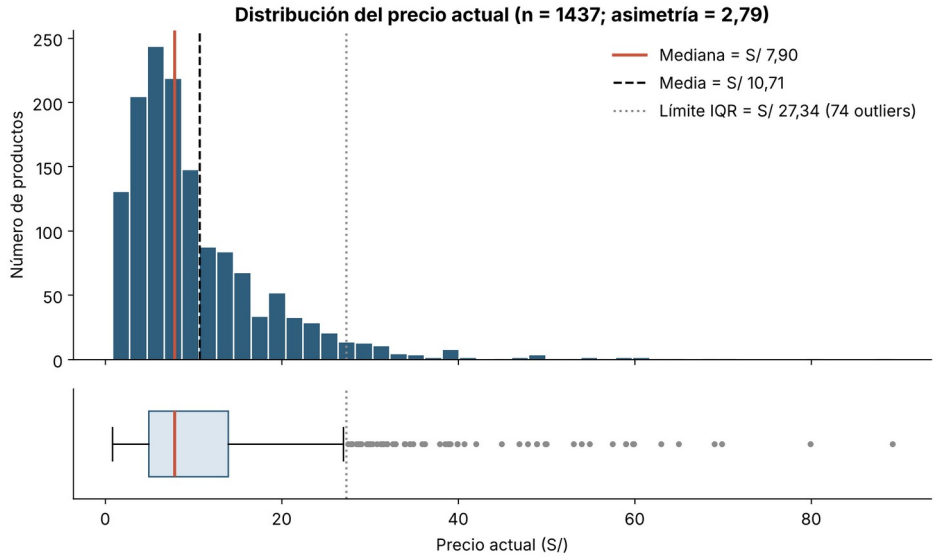
8. ANÁLISIS Y VISUALIZACIÓN DE DATOS

El análisis (`03_analysis.ipynb`) se organiza en siete preguntas (A–G) sobre el dataset final (n = 1437). Criterios comunes: **mediana** como medida central por la asimetría de precios; **n mínimo** de 15 productos por grupo o subcategoría y de 10 por marca, siempre reportado; **IC 95 % de Wilson** para tasas; **Spearman** para relaciones monótonas. Como la muestra no es aleatoria, los intervalos y pruebas se leen como evidencia descriptiva de que una diferencia no se debe solo al tamaño reducido de un segmento, no como inferencia al catálogo completo.

8.A Distribución de precios

La Figura 3 presenta la distribución del precio actual de los 1437 productos del dataset final.

Figura 3. *Distribución del precio actual*

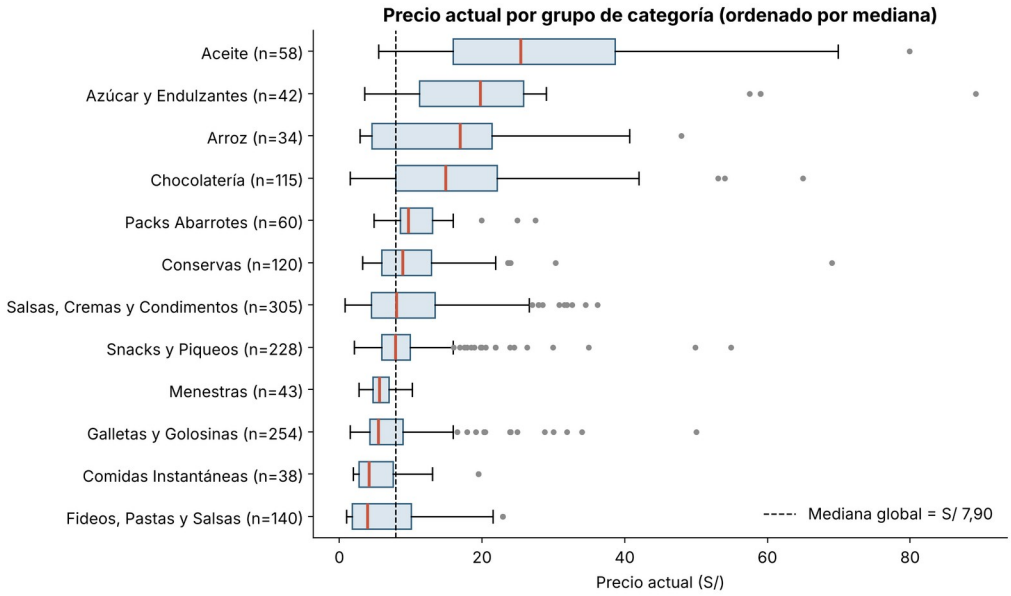


Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la distribución del precio actual de los 1437 productos, con asimetría marcada a la derecha. **Cuánto:** mediana S/ 7,90 frente a media S/ 10,71 (asimetría 2,79); el 50 % central está entre S/ 4,90 y S/ 13,90; el 64,2 % cuesta hasta S/ 10 y el 88,2 % hasta S/ 20; 74 productos superan el límite IQR de S/ 27,34. **Por qué importa:** pocos productos caros inflan la media; por eso todas las comparaciones de la sección usan medianas y rangos intercuartílicos. **Relación con el objetivo:** caracteriza la estructura de precios publicados (OE2).

La Figura 4 compara la dispersión del precio actual entre los 12 grupos de categoría.

Figura 4. *Precio actual por grupo de categoría*

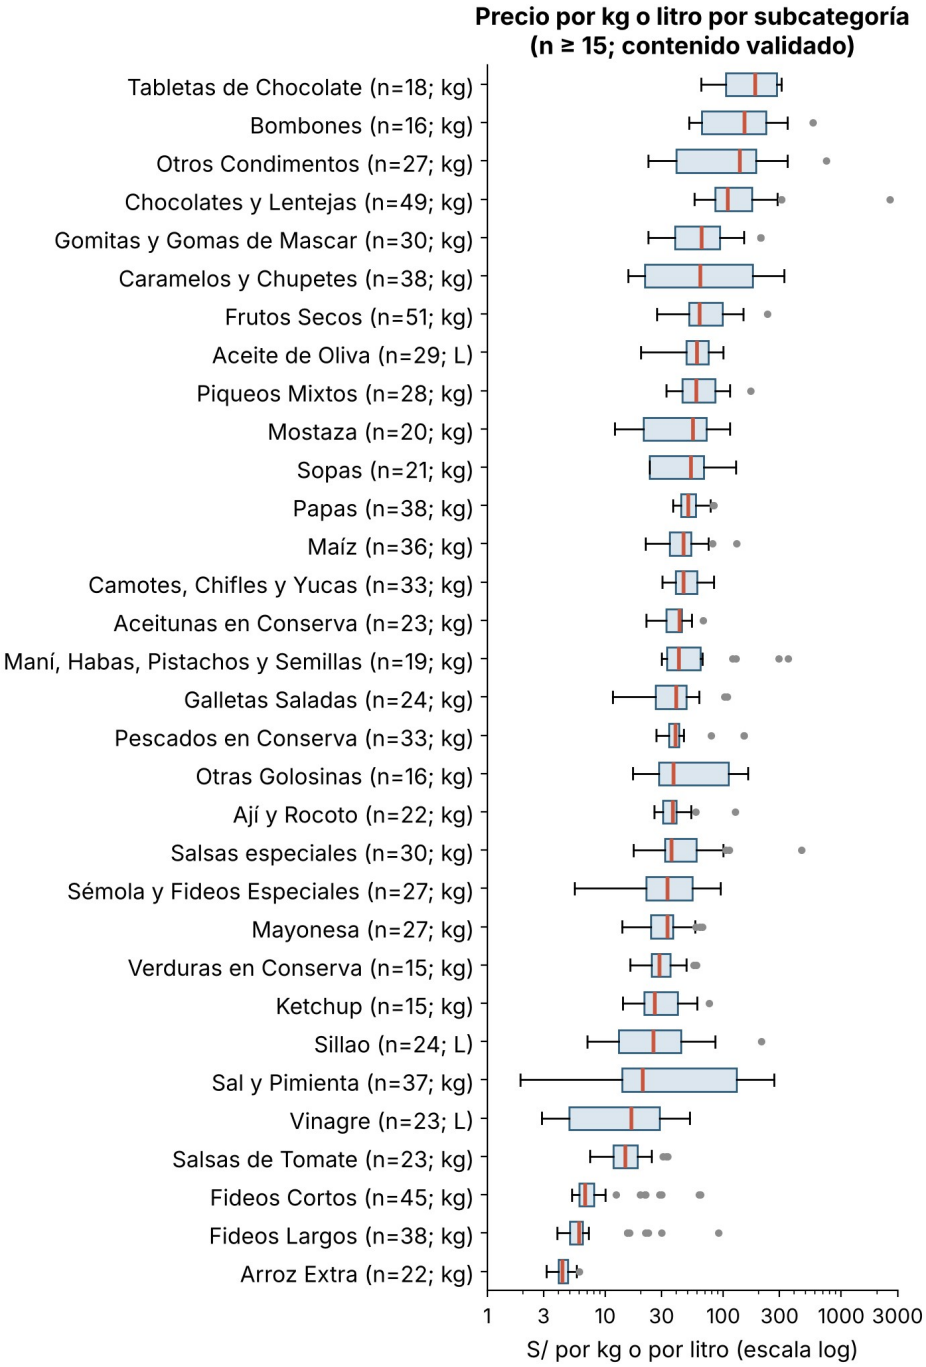


Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la dispersión del precio actual dentro de cada grupo de categoría, ordenados por mediana. **Cuánto:** la mediana va de S/ 3,95 en *Fideos, Pastas y Salsas* a S/ 25,45 en *Aceite*; *Azúcar y Endulzantes* (S/ 19,75) y *Arroz* (S/ 16,95) también superan ampliamente la mediana global; *Aceite* tiene el mayor IQR (S/ 22,75). **Por qué importa:** las diferencias reflejan sobre todo tipos y tamaños de producto distintos; comparar precios absolutos entre grupos no basta, por lo que se normaliza por contenido. **Relación con el objetivo:** describe la variación de precios entre segmentos (OE2) y motiva el uso de `unit_price` y del descuento en %.

Para comparar precios sin el efecto del tamaño del envase, la Figura 5 muestra el precio por kg o por litro dentro de cada subcategoría.

Figura 5. *Precio por kg o por litro dentro de subcategorías (n ≥ 15)*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

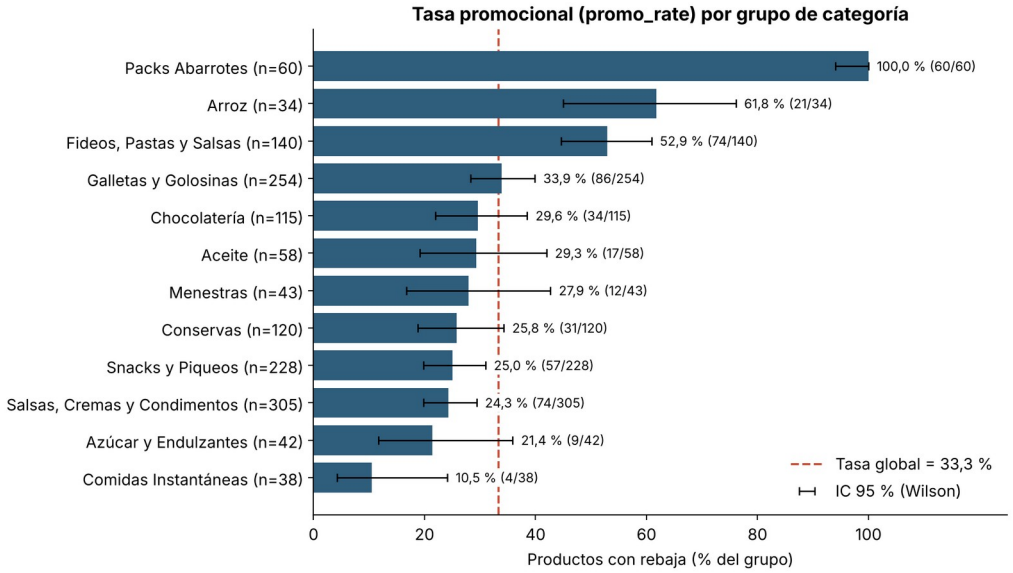
Qué muestra: el precio publicado por kg o por litro dentro de cada subcategoría con n ≥ 15 y contenido validado (escala logarítmica). **Cuánto:** 32 subcategorías (897 productos); el cociente Q3/Q1 va de 1,20 en *Arroz Extra* a 9,35 en *Sal y Pimienta*, con mediana 1,90; la mediana del precio por kg va de S/ 4,32 (*Arroz Extra*) a S/ 186,14 (*Tabletas de Chocolate*). **Por qué importa:** aun normalizado, el cuarto más caro de una subcategoría típica paga

casi el doble por kg o litro que el cuarto más barato; en subcategorías heterogéneas (sal y pimienta juntas, vinagres) la dispersión refleja sobre todo el tipo de producto. **Relación con el objetivo:** profundiza el OE2 y habilita la comparación de precio publicado entre marcas (8.D). Es una diferencia de precio publicado, no una medida de competitividad.

8.B Frecuencia promocional

La Figura 6 muestra la tasa de productos con rebaja por grupo de categoría.

Figura 6. *Tasa promocional por grupo de categoría (IC 95 %)*

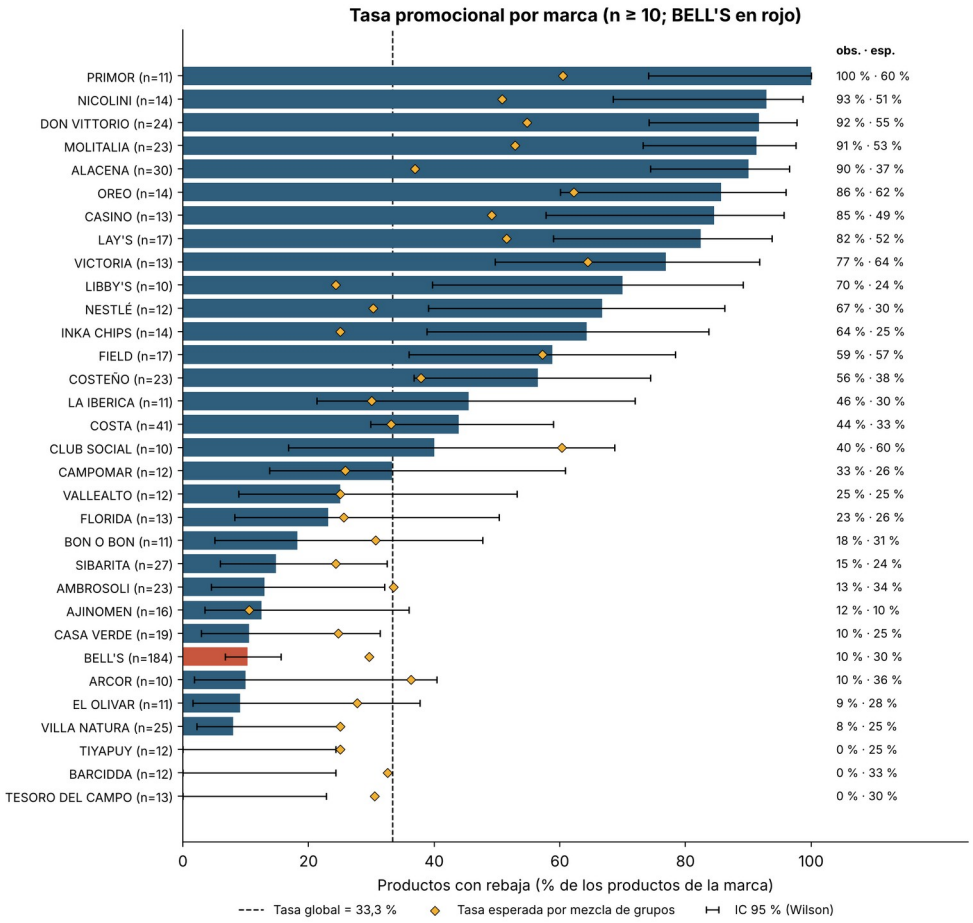


Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la tasa de productos con rebaja por grupo de categoría con su IC 95 % y la tasa global como referencia. **Cuánto:** tasa global 33,3 % (479 de 1437; IC 95 %: 30,9–35,8 %); máximo en *Packs Abarrotes* (100 %; 60/60), *Arroz* (61,8 %; n = 34) y *Fideos, Pastas y Salsas* (52,9 %; n = 140); mínimo en *Comidas Instantáneas* (10,5 %; n = 38). **Por qué importa:** un promedio global oculta diferencias de más de 50 p.p. entre grupos; en seis grupos (*Galletas y Golosinas*, *Chocolatería*, *Aceite*, *Menestras*, *Conservas* y *Azúcar y Endulzantes*) el IC incluye la tasa global, por lo que su diferencia no es concluyente; *Galletas y Golosinas* (33,9 %; 86/254) queda prácticamente en la global. **Relación con el objetivo:** identifica los segmentos con mayor frecuencia promocional observable (OE3).

La Figura 7 compara la tasa promocional de las marcas con al menos 10 productos.

Figura 7. *Tasa promocional por marca (n ≥ 10): observada, IC 95 % y esperada por mezcla de grupos*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la tasa promocional de las 32 marcas con n ≥ 10, su IC 95 % y la tasa esperada si cada marca tuviera la tasa promedio de los grupos en que publica. **Cuánto:** PRIMOR (100 %; n = 11), NICOLINI (92,9 %; n = 14), DON VITTORIO (91,7 %; n = 24), MOLITALIA (91,3 %; n = 23) y ALACENA (90,0 %; n = 30) alcanzan o superan el 90 %; TESORO DEL CAMPO, BARCIDDA y TIYAPUY no muestran rebajas; BELL'S, la marca con más productos (n = 184), tiene 10,3 % frente a una esperada de 29,6 %. **Por qué importa:** el comportamiento es polarizado, pero marca y categoría están entrelazadas (varias marcas con tasa ≥ 90 % publican casi todo en *Fideos*, *Pastas y Salsas*); la tasa esperada controla esa mezcla. Con n entre 10 y 14, el IC tiene un ancho de 22,8 a 51,9 p.p.: las posiciones intermedias no son distinguibles. **Relación con el objetivo:** identifica las marcas con mayor y menor frecuencia promocional con n, incertidumbre y control por categoría (OE3).

Sensibilidad a la imputación. Como el faltante de `presentation` no era aleatorio, se midió cuánto cambia la tasa al excluir los registros imputados (Tabla 15).

Tabla 15. *Sensibilidad de la tasa promocional a los registros imputados y a Packs Abarrotes*

Subconjunto	n	Con rebaja	Tasa (%)	IC 95 % (%)	Diferencia (p.p.)
Todos los productos	1437	479	33,33	30,9–35,8	0,00
Sin registros imputados	1300	403	31,00	28,5–33,6	-2,33
Solo registros imputados	137	76	55,47	47,1–63,5	22,14
Sin Packs Abarrotes	1377	419	30,43	28,1–32,9	-2,90
Sin Packs Abarrotes ni imputados	1277	380	29,76	27,3–32,3	-3,57

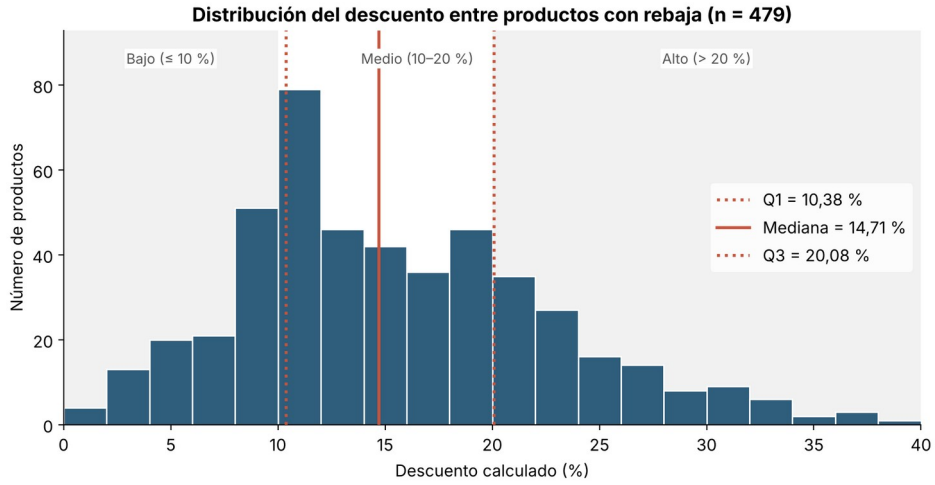
Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la tasa promocional recalculada en cinco subconjuntos del dataset final. **Cuánto:** los imputados tienen 55,47 % de rebaja frente a 31,00 % del resto (Fisher $p < 0{,}001$); excluirlos bajaría la tasa global 2,33 p.p. y, sin Packs ni imputados, 3,57 p.p. (29,76 %). **Por qué importa:** eliminar los nulos habría subestimado la tasa promocional; la sensibilidad acota cuánto dependen los resultados de la calidad del dato. **Relación con el objetivo:** respalda la robustez de la tasa reportada (OE3) y la decisión de imputar (OE1).

8.C Magnitud de los descuentos

La Figura 8 describe la profundidad del descuento entre los productos con rebaja.

Figura 8. *Distribución del descuento entre productos con rebaja*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la distribución del descuento porcentual entre los 479 productos con rebaja, con las franjas de intensidad. **Cuánto:** media 15,45 % y mediana 14,71 %; IQR 10,38–20,08 %; máximo 38,14 %; solo 21 productos (4,4 %) superan 30 %. En soles, el ahorro mediano es S/ 1,10 (máximo S/ 15,80). **Por qué importa:** la cercanía entre media y mediana indica que ~15 % representa bien el descuento típico de la fecha de extracción; los descuentos sobre 30 % son excepcionales y conviene revisarlos uno a uno. **Relación con el objetivo:** cuantifica la profundidad de las promociones (OE4) y respalda empíricamente los cortes 10/20.

La Tabla 16 traduce el descuento continuo a los cuatro niveles de `promotion_intensity`.

Tabla 16. *Distribución de la intensidad promocional (n = 1437)*

Nivel	Rango de `discount_pct`	Productos	% del total	% de los promocionados
Sin descuento	0	958	66,7	–
Bajo	(0; 10]	109	7,6	22,8
Medio	(10; 20]	249	17,3	52,0
Alto	> 20	121	8,4	25,3

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: cómo se reparten los 1437 productos entre los cuatro niveles de intensidad. **Cuánto:** 958 productos (66,7 %) no tienen rebaja; entre los 479 promocionados predomina *Medio* (52,0 %), seguido de *Alto* (25,3 %) y *Bajo* (22,8 %). **Por qué importa:** el nivel *Medio* es el estándar promocional observable; los segmentos con más peso de *Alto* son los de rebajas más profundas. **Relación con el objetivo:** traduce el descuento continuo a niveles comparables entre grupos (OE4; ver 8.E).

8.D Marcas

La muestra está fragmentada: **271 marcas**, de las cuales 239 tienen menos de 10 productos y reúnen el 51,5 % de los registros (76 aparecen una sola vez). **BELL'S** es la marca con más productos (184; 12,8 %), presente en 10 grupos y 53 subcategorías, pero solo 19 tienen rebaja (10,3 %) frente al 36,7 % del resto (n = 1253; $\chi^2 = 50{,}26$; Fisher $p < 0{,}001$). La Tabla 17 comprueba si la diferencia se mantiene dentro de cada grupo.

Tabla 17. *Tasa promocional de BELL'S frente al resto de marcas por grupo de categoría (grupos con ≥ 5 productos BELL'S)*

Grupo de categoría	n BELL'S	Tasa BELL'S (%)	n resto	Tasa resto (%)	Diferencia (p.p.)
Salsas, Cremas y Condimentos	45	0,0	260	28,5	-28,5
Snacks y Piqueos	40	0,0	188	30,3	-30,3
Conservas	23	30,4	97	24,7	5,7
Menestras	15	13,3	28	35,7	-22,4
Aceite	14	7,1	44	36,4	-29,3
Fideos, Pastas y Salsas	14	0,0	126	58,7	-58,7
Azúcar y Endulzantes	13	7,7	29	27,6	-19,9
Galletas y Golosinas	10	20,0	244	34,4	-14,4
Arroz	9	66,7	25	60,0	6,7

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la frecuencia de rebaja de BELL'S y del resto de marcas dentro de los mismos grupos de categoría. **Cuánto:** en 7 de 9 grupos la tasa de BELL'S es menor (p. ej., 0 % frente a 58,7 % en *Fideos, Pastas y Salsas*); las excepciones son *Conservas* (30,4 % frente a 24,7 %) y *Arroz* (66,7 % frente a 60,0 %). Cuando rebaja, su descuento mediano es 8,60 % frente a 15,00 % del resto. **Por qué importa:** la baja frecuencia de BELL'S persiste al controlar por su mezcla de categorías (tasa esperada 29,6 %). Además, su precio mediano por kg o litro es menor que el del resto en 9 de 10 subcategorías comparables (cociente mediano 0,81). Los datos no permiten explicar el motivo de ninguna de las dos diferencias. **Relación con el objetivo:** describe diferencias de comportamiento promocional y de precio publicado entre marcas (OE3).

8.E Grupos de categoría y subcategorías

La intensidad promocional se analiza en dos dimensiones: **cuántos** productos tienen rebaja y **cuánto** se descuenta (Tabla 18).

Tabla 18. *Resumen de precio, frecuencia y profundidad promocional por grupo de categoría*

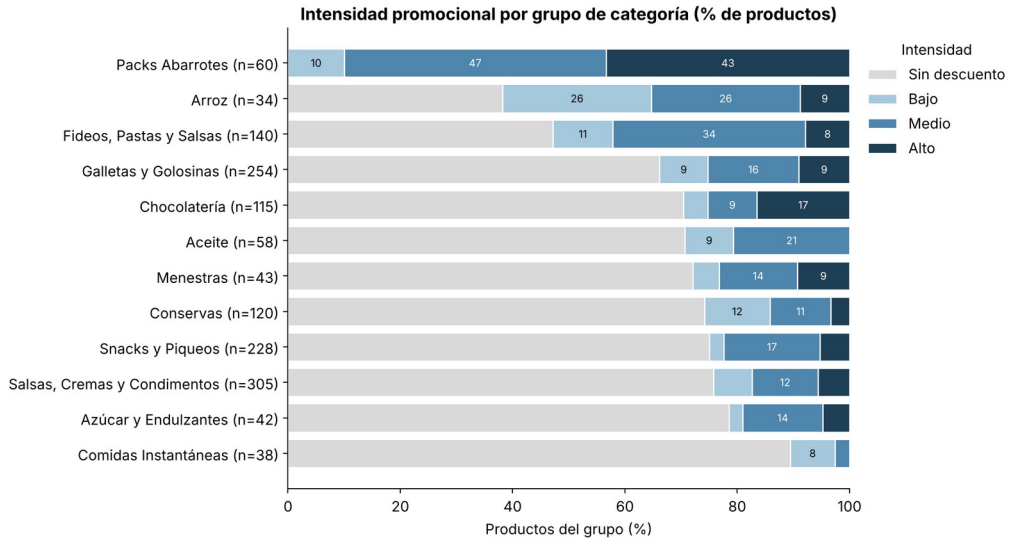
Grupo de categoría	n	Precio mediano (S/)	Tasa promocional (%)	IC 95 % (%)	Descuento mediano (%)	% en Alto
Packs Abarrotes	60	9,70	100,0	94,0–100,0	19,85	43,3
Arroz	34	16,95	61,8	45,0–76,1	10,26	8,8
Fideos, Pastas y Salsas	140	3,95	52,9	44,6–60,9	15,74	7,9
Galletas y Golosinas	254	5,50	33,9	28,3–39,9	11,93	9,1
Chocolatería	115	14,90	29,6	22,0–38,5	20,14	16,5
Aceite	58	25,45	29,3	19,2–42,0	12,92	0,0
Menestras	43	5,60	27,9	16,7–42,7	20,00	9,3
Conservas	120	8,90	25,8	18,8–34,3	10,17	3,3
Snacks y Piqueos	228	7,90	25,0	19,8–31,0	14,49	5,3
Salsas, Cremas y Condimentos	305	8,00	24,3	19,8–29,4	11,95	5,6
Azúcar y Endulzantes	42	19,75	21,4	11,7–35,9	16,75	4,8
Comidas Instantáneas	38	4,15	10,5	4,2–24,1	4,82 *	0,0

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: para cada grupo, el nivel de precio, la frecuencia de rebajas y su profundidad. **Cuánto:** el descuento mediano va de 10,17 % (*Conservas*) a 20,14 % (*Chocolatería*); *Arroz* tiene la segunda mayor tasa (61,8 %) pero un descuento mediano bajo (10,26 %), mientras *Chocolatería* y *Menestras* rebajan menos productos (29,6 % y 27,9 %) con descuentos de ~20 %. (*) Mediana referencial: solo 4 promocionados. **Por qué importa:** frecuencia y profundidad no siempre coinciden; un ranking con una sola métrica ocultaría estos contrastes. **Relación con el objetivo:** responde qué grupos presentan mayor intensidad promocional (OE4).

La Figura 9 combina frecuencia y profundidad en la composición por nivel de intensidad de cada grupo.

Figura 9. *Intensidad promocional por grupo de categoría*

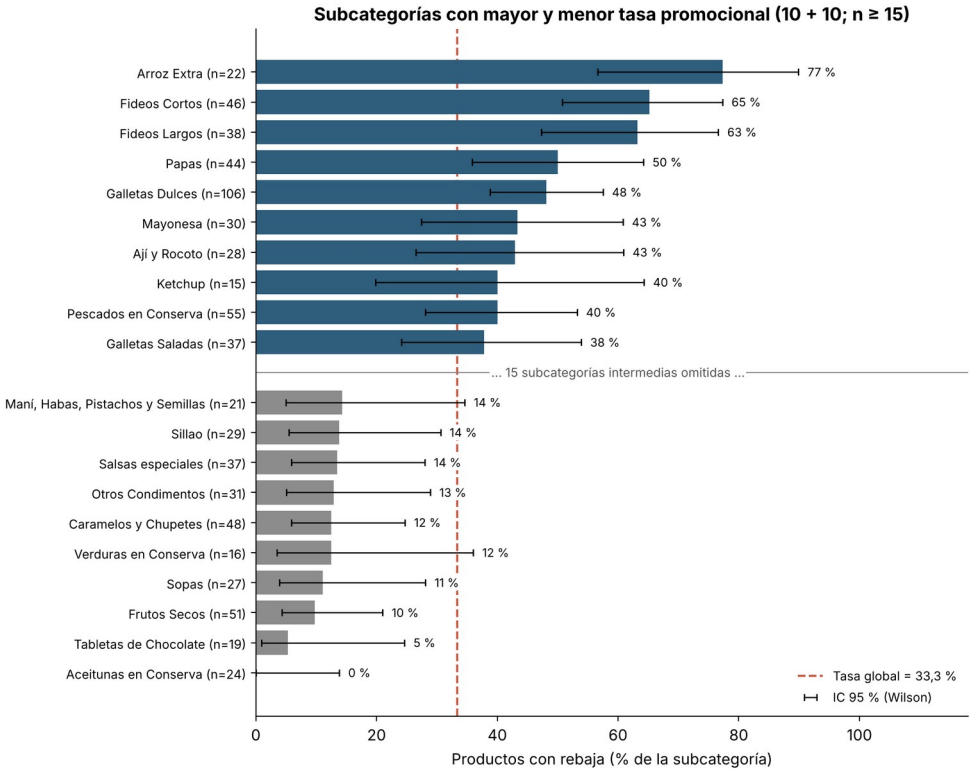


Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la composición de cada grupo por nivel de intensidad promocional (porcentaje de sus productos). **Cuánto:** *Packs Abarrotes* tiene el 43,3 % de sus productos en nivel *Alto* y ninguno sin descuento; entre los demás grupos, *Chocolatería* lidera el nivel *Alto* (16,5 %); *Aceite* y *Comidas Instantáneas* no tienen productos en *Alto*. **Por qué importa:** la figura integra frecuencia (longitud de la parte coloreada) y profundidad (tono) en una sola lectura comparable entre grupos. **Relación con el objetivo:** visualiza la intensidad promocional observable por segmento (OE4).

La Figura 10 desciende al nivel de subcategoría.

Figura 10. *Subcategorías con mayor y menor tasa promocional (n ≥ 15)*



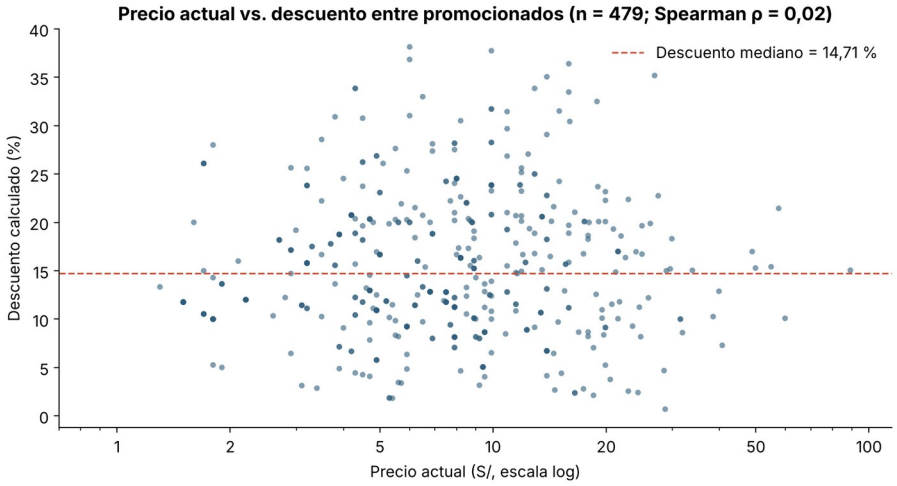
Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: las 10 subcategorías de mayor y las 10 de menor tasa promocional entre las 35 con n ≥ 15 (se excluye *Packs Abarrotes*, sin nivel 3). **Cuánto:** máximo en *Arroz Extra* (77,3 %; n = 22; IC 95 %: 56,6–89,9 %), *Fideos Cortos* (65,2 %; n = 46) y *Fideos Largos* (63,2 %; n = 38); mínimo en *Aceitunas en Conserva* (0 %; n = 24), *Tabletas de Chocolate* (5,3 %; n = 19) y *Frutos Secos* (9,8 %; n = 51). **Por qué importa:** dentro de un mismo grupo conviven comportamientos opuestos (en *Chocolatería*: *Chocolates y Lentejas* 35,9 % frente a *Tabletas de Chocolate* 5,3 %); el grupo por sí solo no describe la actividad promocional. **Relación con el objetivo:** permite focalizar el seguimiento en subcategorías concretas (OE4).

8.F Relaciones entre variables

La Figura 11 relaciona el precio actual con el descuento porcentual.

Figura 11. *Precio actual vs. descuento (%) entre promocionados*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la relación entre el precio actual y el descuento porcentual de los 479 productos con rebaja. **Cuánto:** Spearman ρ = 0,02; la presencia de rebaja tampoco se asocia al precio (ρ = -0,06, n = 1437), mientras que el ahorro en soles crece con el precio regular (ρ = 0,81). **Por qué importa:** productos baratos y caros reciben rebajas porcentuales similares; el ahorro en soles crece por construcción. Es una asociación descriptiva, no una regla de fijación de descuentos. **Relación con el objetivo:** describe cómo varía el descuento según el precio (OE5) y justifica reportar `discount_pct` y `discount_amount` por separado.

La Tabla 19 contrasta la correlación con una medida robusta: el descuento mediano por cuartil de precio.

Tabla 19. *Descuento mediano entre promocionados por cuartil de precio actual*

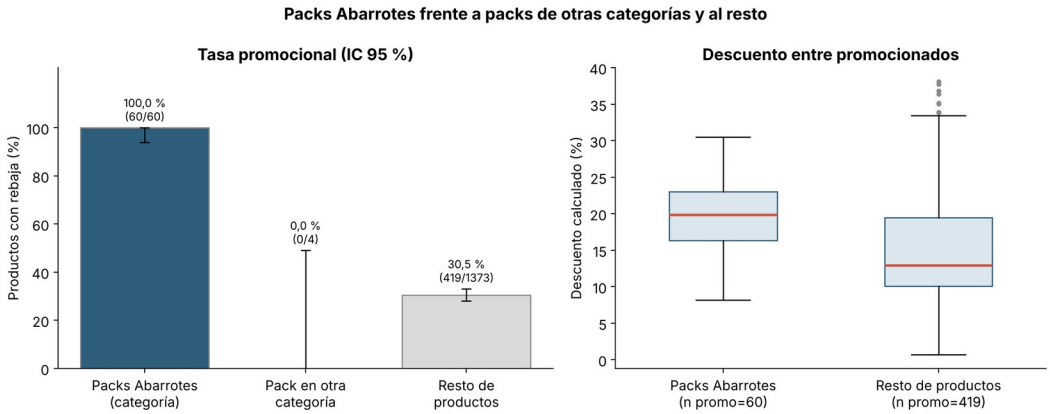
Cuartil de precio actual	Productos con rebaja	Descuento mediano (%)
Q1 (más baratos)	120	14,50
Q2	134	12,79
Q3	107	16,04
Q4 (más caros)	118	15,34

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: el descuento mediano de los promocionados según el cuartil de precio al que pertenecen. **Cuánto:** el descuento mediano se mantiene entre 12,79 % y 16,04 % en los cuatro cuartiles, sin un patrón creciente ni decreciente. **Por qué importa:** confirma con una medida robusta lo que indica la correlación de Spearman: la profundidad relativa no muestra asociación con el nivel de precio. **Relación con el objetivo:** complementa la exploración de relaciones (OE5).

La Figura 12 separa la categoría *Packs Abarrotes* del formato pack.

Figura 12. *Packs Abarrotes frente a packs de otras categorías y al resto de productos*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: la frecuencia de rebaja y el descuento mediano de la categoría *Packs Abarrotes*, de los packs ubicados en otras categorías y del resto de productos. **Cuánto:** *Packs Abarrotes*: 100 % con rebaja (60/60; IC 95 %: 94,0–100 %) y descuento mediano 19,85 %; packs de otras categorías: 0 de 4; resto: 30,5 % y 12,92 %. Sin la categoría, la tasa global baja de 33,3 % a 30,4 % (2,9 p.p.). **Por qué importa:** la alta frecuencia se asocia a la **categoría** del listado y no al **formato** pack; podría reflejar cómo el sitio arma esa categoría (packs creados como oferta), lo que no puede verificarse con estos datos. **Relación con el objetivo:** caracteriza un segmento atípico y cuantifica su peso en la tasa global (OE3 y OE5).

8.G Anomalías y casos extremos

La Tabla 20 lista los cinco mayores descuentos porcentuales y los cinco mayores ahorros en soles.

Tabla 20. *Casos extremos: cinco mayores descuentos porcentuales y cinco mayores ahorros en soles*

Criterio	Producto	Grupo	Precio actual (S/)	Precio regular (S/)	Ahorro (S/)	Descuento (%)
Mayor descuento (%)	Sal de Maras Fina ONZA Doypack 500g	Salsas, Cremas y Condimentos	6,00	9,70	3,70	38,14
Mayor descuento (%)	Passata de Tomate MUTTI Frasco 400g	Fideos, Pastas y Salsas	9,90	15,90	6,00	37,74
Mayor descuento (%)	Tortillas de Maíz TAKIS Buckin' Ranch Bolsa 190g	Snacks y Piqueos	6,00	9,50	3,50	36,84
Mayor descuento (%)	Bombones de Chocolate BON O BON Supreme Caja 144g	Chocolatería	15,90	25,00	9,10	36,40
Mayor descuento (%)	Endulzante SPLENDA Stevia Doypack 175g	Azúcar y Endulzantes	26,90	41,50	14,60	35,18
Mayor ahorro (S/)	Endulzante Natural LAKANTO Sweetener Golden Doypack 800g	Azúcar y Endulzantes	89,20	105,00	15,80	15,05
Mayor ahorro (S/)	Endulzante SPLENDA en Polvo Caja 200 Sobres	Azúcar y Endulzantes	57,50	73,20	15,70	21,45
Mayor ahorro (S/)	Endulzante SPLENDA Stevia Doypack 175g	Azúcar y Endulzantes	26,90	41,50	14,60	35,18
Mayor ahorro (S/)	Pistachos WONDERFUL Jalapeño Bolsa 155g	Snacks y Piqueos	54,90	64,90	10,00	15,41
Mayor ahorro (S/)	Aceite de Oliva ACAVILLE Extra Virgen Botella 1L	Aceite	48,90	58,90	10,00	16,98

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: los productos con valores extremos de descuento relativo y absoluto. **Cuánto:** los descuentos más altos (35–38 %) corresponden a productos de precio bajo o medio de marcas variadas, y los mayores ahorros (S/ 10,00–15,80) a productos caros (endulzantes, pistachos, aceite de oliva). Además hay 12 rebajas simbólicas (< 3 %; ahorro de S/ 0,10 a S/ 0,60), 4 de ellas de BELL'S. **Por qué importa:** ningún caso es un error de captura (precios positivos y coherentes), por lo que se conservan; las rebajas simbólicas recuerdan que `has_discount` mide presencia de rebaja y no su relevancia. **Relación con el objetivo:** delimita qué observaciones pueden influir en promedios y rankings (OE5) y refuerza el uso de medianas.

9. INSIGHTS ENCONTRADOS

Los insights se dirigen al usuario objetivo definido en la sección 2.1: el **analista que monitorea los precios y las promociones publicados** en el canal web, ya trabaje en un equipo de fijación de precios o de gestión de categorías, en inteligencia de mercado o en una marca proveedora. Todos describen la oferta publicada en la muestra extraída; ninguno se refiere a ventas ni a la efectividad de las promociones. Son los mismos cinco insights, con los mismos títulos, del README, la presentación y `metrics.json`.

Insight 1. La frecuencia promocional se concentra en pocos grupos y el promedio global la oculta

Evidencia: Tasa global 33,3 % (479/1437), pero *Packs Abarrotes* 100 % (n = 60), *Arroz* 61,8 % (n = 34) y *Fideos, Pastas y Salsas* 52,9 % (n = 140), frente a 10,5 % en *Comidas Instantáneas* (n = 38) (Figura 6). En subcategorías, de 77,3 % (*Arroz Extra*) a 0 % (*Aceitunas en Conserva*) (Figura 10).

Interpretación: En la muestra extraída, la presencia de rebajas no es uniforme: se concentra en tres grupos y, dentro de ellos, en subcategorías específicas.

Implicación: Un indicador global de promociones subrepresenta las diferencias de más de 50 p.p. entre grupos y puede llevar a comparaciones engañosas entre periodos con distinta mezcla de categorías.

Recomendación para el analista: Reportar la tasa promocional por grupo y subcategoría, con n e IC 95 %, en lugar de un único indicador global, y usar las tasas por grupo de la Tabla 18 como línea base para comparar futuras extracciones.

Insight 2. El descuento típico es moderado (10–20 %) y no se asocia al nivel de precio

Evidencia: Mediana 14,71 %, IQR 10,38–20,08 %, solo 4,4 % de los promocionados sobre 30 % (Figura 8); *Medio* = 52,0 % de los promocionados (Tabla 16); Spearman ρ = 0,02 entre precio y descuento, con medianas de 12,79 % a 16,04 % por cuartil de precio (Tabla 19).

Interpretación: El estándar promocional observable es una rebaja de 10 % a 20 %; productos baratos y caros muestran rebajas porcentuales similares (sin asociación monótona con el precio) y el ahorro en soles crece porque el precio es mayor.

Implicación: Un descuento superior a 20 % ya ubica a un producto en el cuarto superior; los descuentos sobre 30 % y las rebajas simbólicas (< 3 %) son casos que distorsionan los promedios.

Recomendación para el analista: Usar 10 % y 20 % como umbrales de alerta en el tablero de seguimiento, revisar manualmente los descuentos > 30 % y las rebajas < 3 %, y comparar profundidad con `discount_pct`, no con el ahorro en soles.

Insight 3. BELL'S: amplia presencia, rebajas poco frecuentes y menor precio publicado por kg o litro

Evidencia: 184 productos (12,8 % de la muestra) con tasa 10,3 % frente a 36,7 % del resto y 29,6 % esperada por su mezcla de grupos; menor tasa en 7 de 9 grupos (Tabla 17); descuento mediano 8,60 % frente a 15,00 %; precio por kg o litro menor en 9 de 10 subcategorías comparables (cociente mediano 0,81).

Interpretación: En esta muestra, BELL'S rara vez aparece con rebaja, incluso dentro de grupos comparables, y su precio publicado normalizado suele ser menor que el de otras marcas de la misma subcategoría.

Implicación: La tasa promocional de una marca no basta para describir su nivel de precio publicado: una marca con pocas rebajas puede tener precios por kg o litro más bajos. Los datos no permiten explicar el motivo.

Recomendación para el analista: Reportar BELL'S por separado (tasa y precio por kg o litro dentro de subcategoría) para que su peso no sesgue los agregados, y comparar el precio publicado por kg o litro de cada marca con la mediana de su subcategoría como referencia descriptiva, verificando el patrón en varias fechas antes de considerarlo estable.

Insight 4. Comportamiento polarizado entre marcas, entrelazado con la categoría

Evidencia: Entre 32 marcas con n ≥ 10, cinco alcanzan o superan el 90 % (PRIMOR, NICOLINI, DON VITTORIO, MOLITALIA, ALACENA) y tres tienen 0 % (TESORO DEL CAMPO, BARCIDDA, TIYAPUY) (Figura 7). Las cinco primeras superan su tasa esperada por mezcla de grupos en 36,9 a 53,1 p.p.; con n entre 10 y 14 el IC 95 % mide 22,8–51,9 p.p.

Interpretación: La frecuencia promocional observable varía fuertemente entre marcas, pero varias de las más promocionadas publican casi todo en *Fideos, Pastas y Salsas*, el grupo con más rebajas.

Implicación: Una clasificación de marcas sin n, intervalo ni tasa esperada confunde el efecto de la marca con el de su categoría y sobreinterpreta diferencias entre marcas pequeñas.

Recomendación para el analista: Evaluar la frecuencia de rebajas de cada marca frente a la tasa esperada de su mezcla de grupos y no frente al promedio global, exigir n ≥ 10 y mostrar el IC antes de ordenar marcas, y seguir en extracciones posteriores a las cinco marcas con tasa ≥ 90 % y a las tres con 0 %.

Insight 5. Packs Abarrotes: una categoría con rebaja en el 100 % de sus productos que eleva la tasa global

Evidencia: 60 de 60 productos con rebaja, descuento mediano 19,85 % frente a 12,92 % del resto y 43,3 % en nivel *Alto;* los 4 packs ubicados en otras categorías no tienen rebaja; sin la categoría, la tasa global pasa de 33,3 % a 30,4 % (Figura 12, Tabla 15).

Interpretación: La alta frecuencia se asocia a la categoría *Packs Abarrotes* del listado y no al formato pack; podría reflejar cómo el sitio arma esa categoría, lo que no puede verificarse con estos datos.

Implicación: Incluir o no esta categoría cambia la tasa global en 2,9 p.p.; mezclarla con el resto distorsiona las comparaciones entre extracciones.

Recomendación para el analista: Reportar siempre la tasa promocional con y sin *Packs Abarrotes* y analizar esa categoría como un segmento propio.

Recomendaciones priorizadas para el monitoreo

La Tabla 21 traduce los insights en reglas de seguimiento concretas para el analista de monitoreo, ordenadas por prioridad (primero las que cambian la lectura de los indicadores globales).

Tabla 21. *Recomendaciones priorizadas: indicador, umbral o regla y fuente*

Prioridad	Recomendación	Indicador	Umbral o regla	Fuente
1	Reportar la frecuencia promocional segmentada, no solo la global	Tasa promocional por grupo y subcategoría con IC 95 %	Mostrar n e IC; grupos con n ≥ 15; marcar si el IC no incluye la tasa global (33,3 %)	Tabla 18; Figura 6; Figura 10
2	Separar *Packs Abarrotes* del resto	Tasa global con y sin *Packs Abarrotes*	Reportar ambas (33,3 % y 30,4 %); diferencia de 2,9 p.p.	Tabla 15; Figura 12
3	Alertar descuentos profundos y revisar extremos	`discount_pct` por producto	Alerta > 20 % (≈ Q3); revisión manual > 30 % y < 3 %	Tabla 16; Tabla 20; Figura 8
4	Ordenar marcas solo con base suficiente	Tasa por marca, IC 95 % y tasa esperada por mezcla de grupos	n ≥ 10; comparar con la tasa esperada, no con la global	Figura 7; Tabla 17
5	Comparar profundidad en %, no en soles	`discount_pct` frente a `discount_amount`	Usar % entre productos de distinto precio (ρ precio–ahorro = 0,81)	Tabla 19; Figura 11

Fuente: Elaboración propia.

Las cinco reglas pueden automatizarse en un tablero que se recalcule en cada nueva extracción. Ninguna evalúa ventas ni efectividad: todas describen la oferta publicada y deben confirmarse en varias fechas antes de considerarse patrones estables.

10. CONCLUSIONES

10.1 Conclusiones por objetivo

La Tabla 22 resume, para cada objetivo específico, el hallazgo principal, su evidencia y su significado.

Tabla 22. *Conclusiones por objetivo específico: hallazgo, evidencia y significado*

Objetivo	Hallazgo	Evidencia	Significado
OE1. Dataset confiable	El descuento extraído era inválido y la calidad real difería de la reportada; se corrigió sin eliminar filas válidas.	479 rebajas con `discount` = 0; 138 nulos imputados (100 %); 1437 × 21 sin nulos.	Las cifras de promoción se apoyan en una variable reconstruida y verificable.
OE2. Precios	Distribución asimétrica; diferencias grandes entre grupos y, aun por kg o litro, dentro de subcategorías heterogéneas.	Mediana S/ 7,90 < media S/ 10,71; Q3/Q1 de 1,20 a 9,35 (mediana 1,90).	La mediana y la normalización por contenido son imprescindibles para comparar precios.
OE3. Frecuencia	Un tercio de los productos tiene rebaja, con fuerte heterogeneidad por grupo y marca.	33,3 % global; 10,5 %–100 % por grupo; 0 %–100 % por marca; BELL'S 10,3 %.	La tasa debe reportarse segmentada, con n e IC.
OE4. Profundidad e intensidad	El descuento típico es moderado y la intensidad tiene dos dimensiones que no siempre coinciden.	Mediana 14,71 %; *Medio* 52,0 %; *Arroz* 61,8 % de tasa con 10,26 % de descuento.	La intensidad se describe con frecuencia y profundidad a la vez.
OE5. Relaciones y anomalías	El % de descuento no se asocia al precio; Packs Abarrotes es un segmento atípico; los extremos son válidos.	ρ = 0,02; Packs 60/60 frente a 0/4; 6 outliers de descuento y 12 rebajas simbólicas.	% y monto de descuento miden cosas distintas; Packs se analiza aparte.
OE6. Reproducibilidad	El flujo de la zona raw a los entregables se ejecuta con dos notebooks y archivos versionados.	Pipeline de 6 fases; `assert` finales; cifras leídas de `metrics.json`.	Terceros pueden regenerar todos los resultados del informe.

Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Qué muestra: el cumplimiento de cada objetivo específico con su evidencia cuantitativa. **Cuánto:** los seis objetivos se cumplen; los OE3–OE5 dependen de la reconstrucción del descuento lograda en el OE1. **Por qué importa:** conecta los hallazgos con las preguntas planteadas y deja explícito el alcance de cada conclusión. **Relación con el objetivo:** responde al objetivo general: describir precios publicados e intensidad promocional observable en la muestra.

10.2 Limitaciones

- Un solo snapshot: no hay evolución temporal ni duración de promociones.
- Muestra no aleatoria de 30 de ~65 páginas: la composición por grupo y marca depende del orden del listado y los resultados no se generalizan al catálogo.
- El descuento reconstruido solo capta rebajas expresadas en la diferencia entre precio regular y actual.
- Sin datos de ventas, costos ni stock real: no se evalúan demanda, rentabilidad, efectividad ni competitividad.
- Precio unitario comparable solo dentro de subcategorías homogéneas y con contenido validado.

10.3 Reflexión crítica

El hallazgo más importante del proyecto no fue analítico sino de calidad: una línea de limpieza (`fillna(0)`) convirtió un fallo de captura en «sin promoción» y, sin la validación de reglas de dominio, todo el análisis de descuentos habría concluido erróneamente que no existían rebajas. La lección es que la auditoría del dato debe preceder a cualquier interpretación y que los valores por defecto deben distinguir

«no observado» de «cero». También se aprendió a contener la interpretación: las diferencias llamativas entre marcas o grupos deben leerse junto con la mezcla de categorías (que en BELL'S no basta para reproducir la diferencia: 10,3 % observada frente a 29,6 % esperada) y con la forma en que el sitio organiza su catálogo (*Packs Abarrotes*); una muestra ordenada de una sola fecha no permite atribuir causas. Por eso el informe reporta n, intervalos, tasas esperadas y análisis de sensibilidad junto a cada cifra.

10.4 Extensiones futuras

- **Panel temporal:** programar extracciones periódicas con fecha para medir la duración y recurrencia de las rebajas.
- **Cobertura completa:** recorrer las ~65 páginas o muestrear páginas al azar para reducir el sesgo de orden.
- **Captura robusta del descuento:** guardar el texto crudo del porcentaje, validar contra los precios en la extracción y registrar el tipo de promoción.
- **Tablero de monitoreo:** automatizar las reglas de la Tabla 21 (tasas por grupo y marca, umbrales de alerta 10/20 % y revisión de casos extremos).

11. DOCUMENTACIÓN Y REPRODUCIBILIDAD EN GITHUB

Repositorio: [enlace al repositorio GitHub del equipo] *(por completar con la URL pública antes de la entrega).*

El repositorio contiene los datos inicial y final, los notebooks numerados por etapa, las salidas del análisis y la documentación exigida. El `README.md` describe el problema, el alcance, la estructura, los pasos de ejecución, el diccionario resumido y las limitaciones.

11.1 Estructura de carpetas

```
proyecto_plazavea/
├── README.md                     # descripción, ejecución y alcance
├── requirements.txt              # dependencias con versiones
├── .gitignore
├── data/
│   ├── raw/productos_plazavea_raw.csv          # dataset inicial (1438 × 12)
│   └── processed/
│       ├── productos_plazavea_clean.csv         # limpio completo (1438 × 29)
│       └── productos_plazavea_final.csv         # dataset final (1437 × 21)
├── notebooks/
│   ├── 01_acquisition.ipynb      # scraping (Colab; no se re-ejecuta)
│   ├── 02_preprocessing.ipynb    # limpieza, features, reducción
│   └── 03_analysis.ipynb         # análisis A–G, figuras y métricas
├── scripts/
│   ├── diagrama_pipeline.py      # genera reports/figures/pipeline.png
│   ├── figuras_presentacion.py   # figuras legibles para la presentación
│   └── build_diccionario_final.py  # genera docs/diccionario_final.docx
├── templates/Formato_Diccionario_de_datos.docx  # plantilla del diccionario
├── reports/
│   ├── figures/                  # 19 figuras + pipeline.png (+ presentacion/)
│   ├── tables/                   # tablas CSV exportadas
│   ├── metrics.json              # todas las cifras del informe
│   └── metrics_preprocesamiento.json
└── docs/
    ├── diccionario_inicial.pdf / .docx
    ├── diccionario_final.pdf / .docx
    ├── auditoria_inicial.md
    ├── informe_final.pdf / .docx
    ├── presentacion_final.pptx / .pdf
    ├── guion_presentacion.md
    ├── checklist_rubrica.md
    └── PLAN_COMMITS.md           # plan de commits por integrante
```

11.2 Cómo ejecutar

Requisitos: Python 3 y las dependencias de `requirements.txt` (pandas 3.0.5, numpy 2.5.3, matplotlib 3.11.2, seaborn 0.13.2, nbconvert 7.17.2 e ipykernel; Selenium y BeautifulSoup solo para el notebook 01 en Colab).

```
git clone [enlace al repositorio GitHub del equipo]
cd proyecto_plazavea
python -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt
sha256sum data/raw/productos_plazavea_raw.csv           # 3a3833e8…4348f3a
jupyter nbconvert --to notebook --execute --inplace notebooks/02_preprocessing.ipynb
jupyter nbconvert --to notebook --execute --inplace notebooks/03_analysis.ipynb
```

El notebook 02 regenera `data/processed/` y el registro de calidad; el 03 regenera `reports/figures`, `reports/tables` y `reports/metrics.json`. Ambos usan rutas relativas y terminan con validaciones

`assert`, de modo que una ejecución que no reproduzca las cifras oficiales (1437 registros, 0 nulos, 0 duplicados) se detiene con error. El notebook 01 documenta la adquisición; requiere Google Colab, Chrome y acceso a plazavea.com.pe, y cada nueva ejecución produce un snapshot distinto.

11.3 Control de versiones

El historial se organizará en commits lógicos, uno por unidad de trabajo verificable, hechos por cada integrante desde su propia cuenta de GitHub. La Tabla 23 presenta el **plan de commits** acordado (detallado en `docs/PLAN_COMMITS.md`); una vez publicado el repositorio, el historial real se consulta con `git log`.

Tabla 23. *Plan de commits del repositorio (por ejecutar desde la cuenta de cada integrante)*

N.º	Mensaje de commit	Contenido	Responsable
1	`chore: estructura inicial, README y .gitignore`	Carpetas `data`, `notebooks`, `reports`, `docs`	J. Justo
2	`data: agrega dataset raw oficial (1438 x 12)`	`data/raw` + hash sha256	S. Loli
3	`docs: diccionario inicial y auditoría del dataset raw`	`docs/diccionario_inicial`, `auditoria_inicial.md`	P. Ortiz
4	`feat(prep): integración, reglas de dominio y faltantes`	`02_preprocessing.ipynb` (secciones 1–4)	S. Loli
5	`feat(prep): outliers, transformación y registro de calidad`	`02_preprocessing.ipynb` (secciones 5, 6, 9)	S. Loli
6	`feat(features): variables derivadas y dataset final`	Secciones 7, 8 y 10; `data/processed`	P. Ortiz
7	`feat(analysis): análisis A–G, figuras y metrics.json`	`03_analysis.ipynb`, `reports/`	D. Alarcon
8	`docs: diccionario final`	`docs/diccionario_final`	P. Ortiz
9	`build: requirements.txt y verificación de reproducibilidad`	`requirements.txt`, README (ejecución)	J. Justo
10	`docs: informe final y presentación`	`docs/informe_final`, `presentacion_final.pptx`	S. García

Fuente: Elaboración propia.

El plan agrupa los commits por etapa del pipeline con la convención `tipo(ámbito): descripción` y asigna las secciones del notebook 02 igual que la Tabla 1 (Sebastian Loli: 1–6 y 9; Piero Ortiz: 7, 8 y 10). Un historial ordenado permitirá auditar cuándo y por qué cambió cada artefacto y evidenciará el aporte de cada integrante.

11.4 Trazabilidad de figuras

La Tabla 24 indica qué archivo y qué notebook o script producen cada figura del informe, incluidas las del Anexo A. La presentación usa la misma numeración; sus versiones para proyección se generan con `scripts/figuras_presentacion.py`.

Tabla 24. *Correspondencia entre las figuras del informe y los archivos del repositorio*

Figura	Archivo	Generada en
Figura 1	`reports/figures/pipeline.png`	`scripts/diagrama_pipeline.py`
Figura 2	`reports/figures/fig01_valores_faltantes.png`	02_preprocessing.ipynb
Figura 3	`reports/figures/fig02_distribucion_precio_actual.png`	03_analysis.ipynb
Figura 4	`reports/figures/fig03_precio_por_category_group.png`	03_analysis.ipynb
Figura 5	`reports/figures/fig04_precio_unitario_subcategoria.png`	03_analysis.ipynb
Figura 6	`reports/figures/fig05_promo_rate_category_group.png`	03_analysis.ipynb
Figura 7	`reports/figures/fig06_promo_rate_marcas.png`	03_analysis.ipynb
Figura 8	`reports/figures/fig07_distribucion_descuento.png`	03_analysis.ipynb
Figura 9	`reports/figures/fig10_intensidad_por_category_group.png`	03_analysis.ipynb
Figura 10	`reports/figures/fig11_promo_rate_subcategorias.png`	03_analysis.ipynb
Figura 11	`reports/figures/fig13_precio_vs_descuento.png`	03_analysis.ipynb
Figura 12	`reports/figures/fig14_packs_abarrotes_vs_resto.png`	03_analysis.ipynb
Figura A1	`reports/figures/figA1_outliers_precio_actual.png`	02_preprocessing.ipynb
Figura A2	`reports/figures/figA2_outliers_precio_regular.png`	02_preprocessing.ipynb
Figura A3	`reports/figures/figA3_outliers_descuento_pct.png`	02_preprocessing.ipynb
Figura A4	`reports/figures/figA4_top_marcas_productos.png`	03_analysis.ipynb
Figura A5	`reports/figures/figA5_regular_vs_actual.png`	03_analysis.ipynb
Figura A6	`reports/figures/fig08_intensidad_promocional.png`	03_analysis.ipynb
Figura A7	`reports/figures/fig09_descuento_por_category_group.png`	03_analysis.ipynb
Figura A8	`reports/figures/fig12_precio_con_vs_sin_rebaja.png`	03_analysis.ipynb

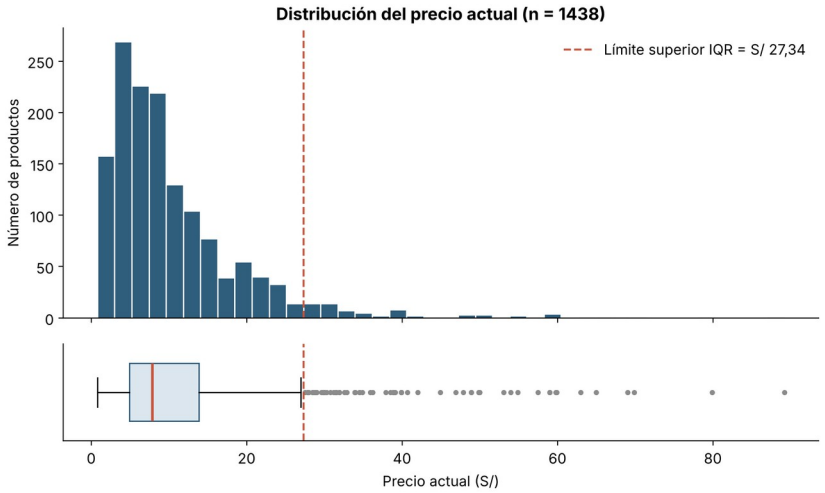
Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

El informe contiene 20 figuras: 12 en el cuerpo (11 generadas por los notebooks 02 y 03 y el diagrama del pipeline, generado por un script) y 8 en el Anexo A. Ninguna se editó manualmente y todas pueden regenerarse desde el código, lo que completa la reproducibilidad del informe (OE6).

ANEXO A. FIGURAS COMPLEMENTARIAS

Este anexo reúne las figuras de apoyo generadas por los notebooks que no se discuten en el cuerpo del informe. Cada una incluye una línea de lectura y la sección del cuerpo a la que complementa.

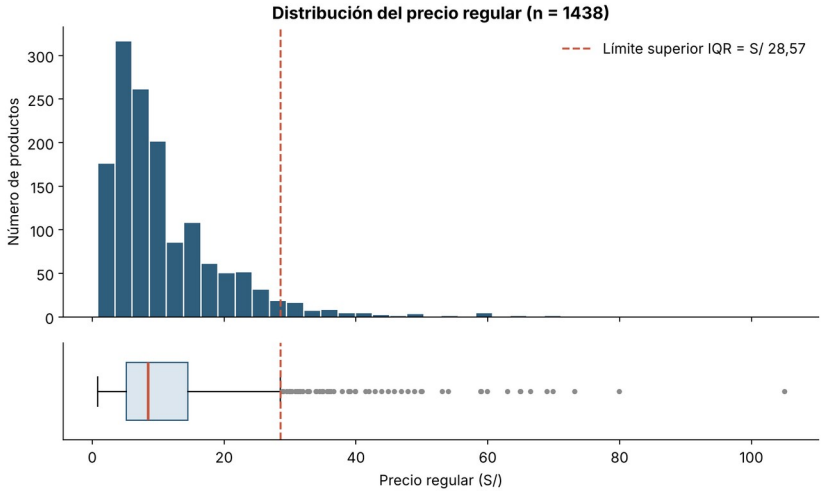
Figura A1. *Outliers del precio actual según el criterio IQR (n = 1438)*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Lectura: Precio actual: la caja se concentra bajo S/ 15 y los 74 valores sobre S/ 27,34 son productos válidos (complementa la Tabla 10, sección 6.5).

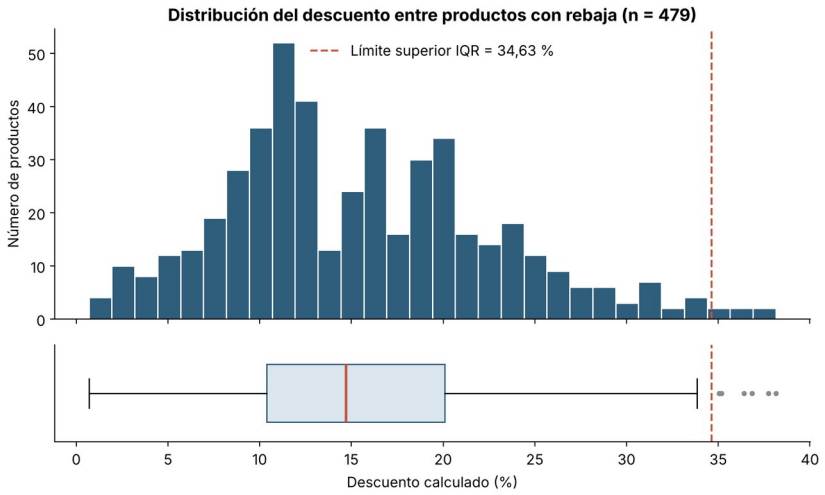
Figura A2. *Outliers del precio regular según el criterio IQR (n = 1438)*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Lectura: Precio regular: el patrón es el mismo que el del precio actual, con 74 valores atípicos; por eso no se crea un indicador adicional (sección 6.5).

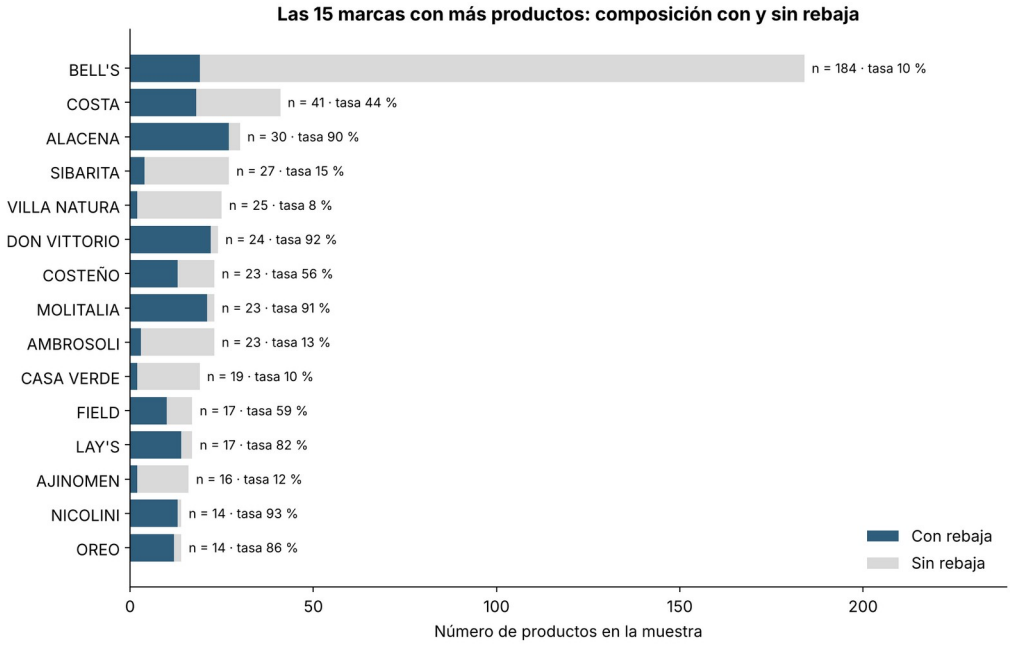
Figura A3. *Outliers del descuento entre productos con rebaja según el criterio IQR (n = 479)*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Lectura: Descuento entre los 479 promocionados: solo 6 valores superan el límite de 34,63 % y se conservan (sección 6.5 y 8.G).

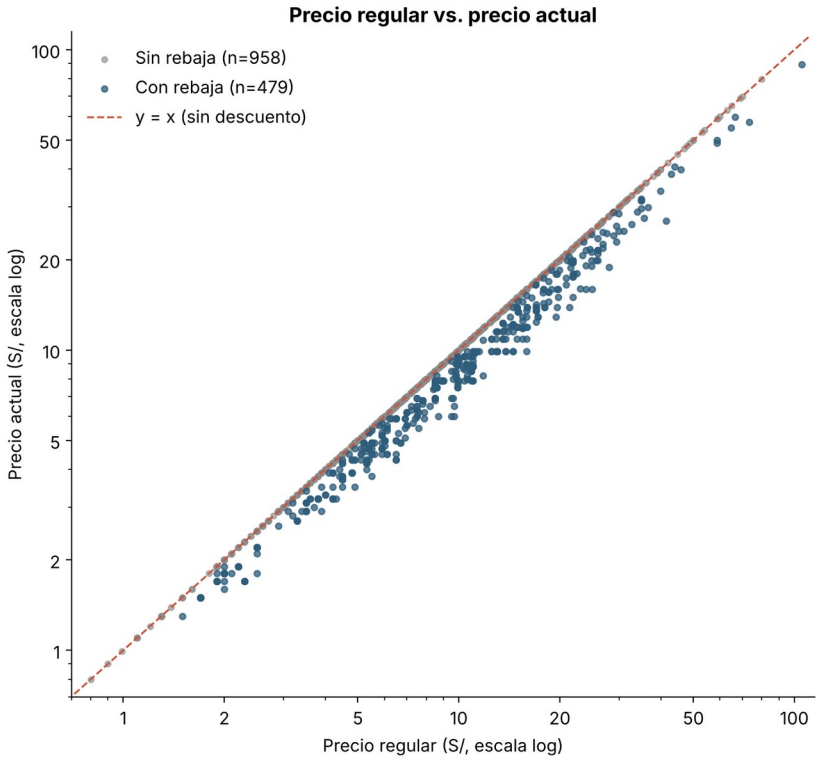
Figura A4. *Las 15 marcas con más productos: composición con y sin rebaja*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Lectura: Las 15 marcas con más productos: BELL'S (n = 184) domina la muestra con una fracción pequeña de productos con rebaja (complementa la Figura 7 y la sección 8.D).

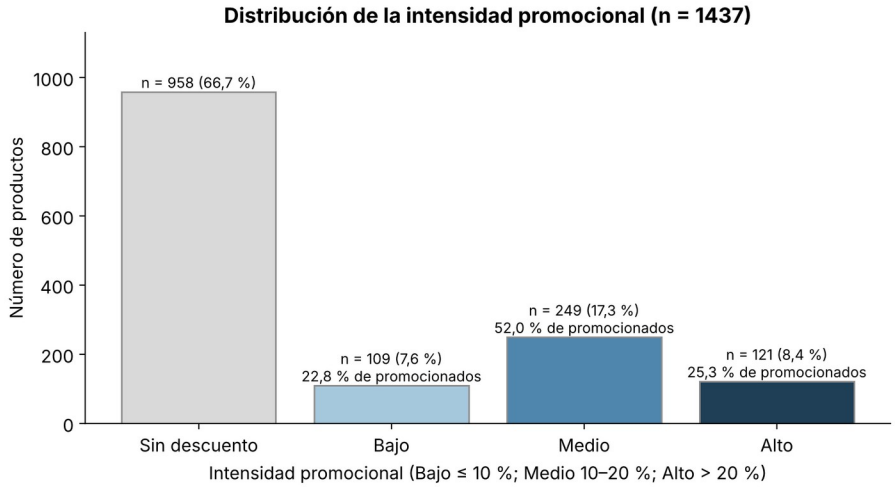
Figura A5. *Precio regular vs. precio actual (validación de consistencia)*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Lectura: Precio regular frente a precio actual: 958 productos sobre la diagonal (sin rebaja), 479 por debajo y ninguno por encima, lo que valida la base de `discount_pct` (sección 8.F).

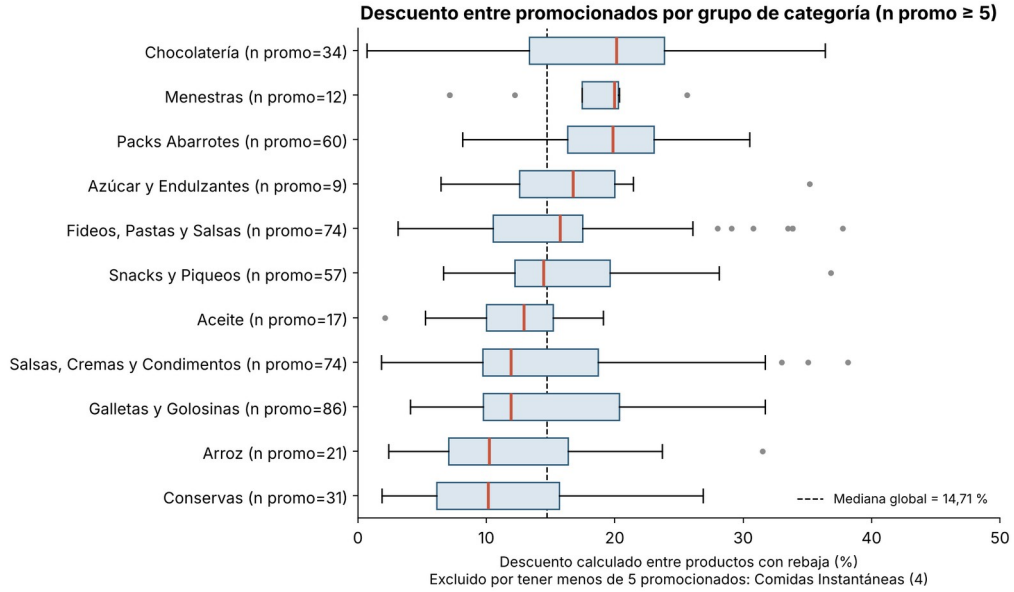
Figura A6. *Distribución de la intensidad promocional*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Lectura: Distribución de los 1437 productos por nivel de intensidad promocional (complementa la Tabla 16, sección 8.C).

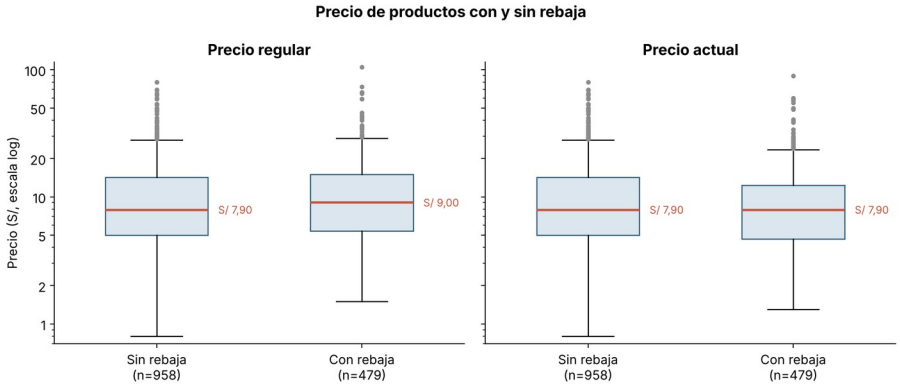
Figura A7. *Descuento entre promocionados por grupo de categoría (n promo ≥ 5)*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Lectura: Descuento entre promocionados por grupo de categoría con al menos 5 promocionados (complementa la Tabla 18, sección 8.E).

Figura A8. *Precio regular y actual de productos con y sin rebaja*



Fuente: Elaboración propia a partir de datos extraídos de plazavea.com.pe.

Lectura: Precio regular de los productos con y sin rebaja: rangos intercuartílicos muy superpuestos (sección 8.F).